

Pre-THesis-submitted

by Eliseo Villalobos

Submission date: 17-Oct-2025 08:09PM (UTC-0700)

Submission ID: 2774876217

File name: Pre-THesis-submitted.docx (1,022.68K)

Word count: 9007

Character count: 59678

**DETEKSI SINYAL ECG NORMAL DAN ABNORMAL MENGGUNAKAN
JARINGAN SARAF KONVOLUSIONAL 1D PADA DATASET MIT-BIH
YANG TELAH DIMODIFIKASI**

SKRIPSI

Oleh

Abdiel Ivan Rivandi 2602164282

Petra Michael 2602075812



1 Computer Science Study Program

School of Computer Science

Universitas Bina Nusantara

BANDUNG

2025

**DETEKSI SINYAL ECG NORMAL DAN ABNORMAL MENGGUNAKAN
JARINGAN SARAF KONVOLUSIONAL 1D PADA DATASET MIT-BIH
YANG TELAH DIMODIFIKASI**

**11
SKRIPSI**

diajukan sebagai salah satu syarat
untuk gelar kesarjanaan pada
Program Studi Teknik Informatika
Jenjang Pendidikan Strata-1

Oleh

ABDIEL IVAN RIVANDI 2602164282

PETRA MICHAEL 2602075812



**1
Computer Science Study Program**

School of Computer Science

Universitas Bina Nusantara

BANDUNG

2025

Pernyataan Kesiapan Skripsi untuk Ujian Pendadaran

Pernyataan Penyusunan Skripsi

Kami, Abdiel Ivan Rivandi,

Petra Michael

[98] Dengan ini menyatakan bahwa Skripsi yang berjudul:

**DETEKSI SINYAL ECG NORMAL DAN ABNORMAL MENGGUNAKAN
JARINGAN SARAF KONVOLUSIONAL 1D PADA DATASET MIT-BIH
YANG TELAH DIMODIFIKASI**
**[4] DETECTION OF NORMAL AND ABNORMAL ECG SIGNALS USING A 1D
CONVOLUTIONAL NEURAL NETWORK ON A MODIFIED MIT-BIH
DATASET**

**[23] Adalah benar hasil karya kami dan belum pernah diajukan sebagai karya ilmiah,
sebagian atau seluruhnya, atas nama kami atau pihak lain**

Abdiel Ivan Rivandi

2602164282

PetraMichael

2602075812

[1] Disetujui oleh Pembimbing

Saya setuju Skripsi tersebut layak diajukan untuk Ujian Pendadaran

Dr. Dani Suandi, S.Si., M.Si.
D6532

Computer Science Study Program
School of Computer Science
Skripsi Sarjana Teknik Informatika

**4
DETECTION OF NORMAL AND ABNORMAL ECG
SIGNALS USING A 1D CONVOLUTIONAL NEURAL
NETWORK ON A MODIFIED MIT-BIH DATASET**

Abdiel Ivan Rivandi 2602164282

Petra Michael 2602164282

ABSTRACT

This study explores the application of a one-dimensional Convolutional Neural Network (1D CNN) to classify electrocardiogram (ECG) signals into two categories: normal and abnormal. The dataset is a modified version of the MIT-BIH Arrhythmia Dataset, which has undergone preprocessing steps such as normalization and outlier removal to enhance signal quality. The 1D CNN model was designed to identify temporal patterns in ECG signals without manual feature engineering. Evaluation using metrics such as accuracy, precision, recall, F1-score, and AUC-ROC demonstrates reliable performance in binary classification. The results highlight the effectiveness of CNN-based deep learning approaches in Arrhythmia detection and indicate strong potential for integration into wearable devices for real-time cardiac monitoring.

Keywords: ECG, Arrhythmia, 1D CNN, Signal Classification, Cardiac Detection

ABSTRAK

Penelitian ini membahas penerapan model Convolutional Neural Network (CNN) satu dimensi (1D) untuk klasifikasi sinyal elektrokardiogram (ECG) menjadi dua kategori: normal dan abnormal. Data yang digunakan berasal dari MIT-BIH *Arrhythmia* Dataset yang telah dimodifikasi melalui proses normalisasi dan penghapusan outlier guna meningkatkan kualitas sinyal. Model CNN 1D dirancang untuk menemukan pola temporal dalam sinyal jantung tanpa memerlukan rekayasa fitur manual. Evaluasi dilakukan dengan metrik akurasi, precision, recall, F1-score, dan AUC-ROC, yang menunjukkan kinerja model yang andal dalam deteksi biner. Hasil penelitian ini menunjukkan bahwa pendekatan *deep learning* berbasis CNN efektif dalam mengidentifikasi *arrhythmia* dan memiliki potensi besar untuk diterapkan pada perangkat wearable sebagai sistem pemantauan jantung otomatis dan real-time. Studi ini berkontribusi dalam pengembangan metode klasifikasi sinyal medis yang efisien, akurat, dan dapat diandalkan di lingkungan klinis maupun non-klinis.

Kata Kunci: ECG, *Arrhythmia*, CNN 1D, Klasifikasi Sinyal, Deteksi Jantung

Kata Pengantar

Puji dan syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa atas berkat dan rahmat-Nya, sehingga penulis dapat menyelesaikan penyusunan skripsi yang berjudul “Deteksi Sinyal ECG Normal dan Abnormal Menggunakan Jaringan Saraf Konvolusional 1D pada Dataset MIT-BIH yang Telah Dimodifikasi” dengan baik dan tepat waktu.

Skripsi ini disusun sebagai salah satu syarat untuk memperoleh gelar Sarjana pada Program Studi Teknik Informatika, Universitas Bina Nusantara. Penulis menyadari bahwa keberhasilan penyusunan skripsi ini tidak terlepas dari dukungan, bimbingan, dan bantuan dari berbagai pihak. Oleh karena itu, penulis dengan tulus mengucapkan terima kasih kepada:

1. Ibu Dr. Nelly, S.Kom., M.M., CSCA, selaku Rektor Binus University²⁶
2. Bapak Dr. Johan Muliadi Kerta, S.Kom., M.M. selaku *Campus Director* Universitas Bina Nusantara @Bandung.
3. Bapak Prof. Dr. Ir. Derwin Suhartono, S.Kom., MTI, selaku *Dean of School of Computer Science*.
4. Bapak Prof. Dr. Ir. Derwin Suhartono, S.Kom., MTI, selaku *Head of Computer Science Study Program*.
5. Bapak Dr. Dani Suandi, S.Si., M.Si., selaku dosen pembimbing, atas bimbingan, waktu, dan pengetahuan yang sangat berarti dalam proses penelitian ini.³⁰
6. Kedua orang tua dan keluarga kami, atas doa, dukungan moral dan material, serta semangat yang tak ternilai selama masa studi dan penyusunan skripsi ini.¹³
7. Teman-teman dan semua pihak yang tidak dapat disebutkan satu per satu, yang telah membantu secara langsung maupun tidak langsung dalam menyelesaikan skripsi ini.⁸¹

Penulis menyadari bahwa skripsi ini masih jauh dari sempurna. Oleh karena itu, penulis membuka diri terhadap kritik dan saran yang membangun demi penyempurnaan karya ini. Semoga skripsi ini dapat memberikan manfaat bagi pengembangan ilmu pengetahuan, khususnya di bidang pengolahan sinyal medis dan kecerdasan buatan.

Jakarta, 13 Juni 2025

Tim Penulis

DAFTAR ISI

HALAMAN SAMPUL.....	i
HALAMAN JUDUL.....	ii
HALAMAN PERNYATAAN ORISINALITAS.....	iii
ABSTRAK.....	iv
KATA PENGANTAR.....	v
DAFTAR ISI.....	vi
DAFTAR TABEL.....	vii
DAFTAR GAMBAR.....	viii
BAB 1 PENDAHULUAN.....	1
1.1 Latar Belakang.....	1
1.2 Rumusan masalah.....	2
1.3 Hipotesis.....	4
1.4 Ruang lingkup penelitian.....	5
1.4.1 Dataset.....	3
1.4.2 Fokus klasifikasi.....	3
1.4.3 Metode.....	7
1.4.4 Aspek yang tidak dibahas.....	3
1.5 Tujuan dan manfaat penelitian.....	3
1.5.1 Tujuan penelitian.....	3
1.5.2 Manfaat penelitian.....	4
1.6 Sistematika penulisan.....	5
BAB 2 TINJAUAN REFERENSI.....	6
2.1 Elektrokardiogram.....	6
2.2 Denoising dalam pemrosesan sinyal <i>ECG</i>	6
2.3 Deteksi <i>arrhythmia</i> , sinyal abnormal dan variabilitas sinyal.....	7
2.4 Heart rate variability.....	9
2.5 DatasetMIT-BH <i>arrhythmia</i>	9
2.6 Modifikasi Data.....	10
2.7 Persiapan data.....	11
2.8 CNN dan CONV-1D.....	12
2.9 Auto Encoder.....	13
2.10 Kinerja Model.....	17
2.11 Related works.....	15
BAB 3 METODE PENELITIAN.....	19
3.1 Pendekatan penelitian.....	19
3.2 Tahapan penelitian.....	20
3.3 Analisis dan perancangan model 1D-CNN.....	23
3.3.1 Analisis kebutuhan model.....	23
3.3.2 Perancangan arsitektur 1D-CNN.....	23
3.4 Pengembangan dan implementasi model.....	24
3.5 Pelatihan dan validasi model.....	24
3.6 Analisis hasil dan pembuktian hipotesis.....	24
15 BAB 4 HASIL DAN PEMBAHASAN	
BAB 5 KESIMPULAN DAN SARAN	
REFERENSI.....	26

DAFTAR TABEL

Tabel 2.1	Tabel Related Works.....	16
------------------	--------------------------	----

DAFTAR GAMBAR

²²		
Gambar 2.1.	Sinyal Elektrokardiogram.....	7
Gambar 2.2	Denoising Elektrokardiogram.....	8
Gambar 2.3.	Takikardia Ventrikel (VT).....	8
Gambar 2.4.	Fibrilasi Ventrikular (VF)	8
Gambar 2.5.	Fibrilasi Atrium (AF)	8
Gambar 2.6.	Arsitektur 1D-CNN.....	14
Gambar 2.7.	<i>Confusion Matrix</i>	16
Gambar 3.1.	CRISP-DM Model.....	19
Gambar 3.2.	Tahapan Penelitian.....	21

**15
BAB 1****PENDAHULUAN****1.1 Latar Belakang**

Penyakit kardiovaskular masih menjadi penyebab **utama** morbiditas dan mortalitas **di** seluruh dunia, dengan *Arrhythmia* jantung—detak jantung yang tidak normal atau tidak teratur—menjadi indikator kritis kesehatan jantung (Ahmed et al., 2025; Acharya et al., 2017; Sannino & De Pietro, 2021). Beberapa jenis *Arrhythmia* dapat tidak berbahaya, namun banyak di antaranya berpotensi menyebabkan kondisi medis serius, termasuk serangan jantung dan kematian mendadak (Ahmed et al., 2025). Oleh karena itu, deteksi dini *Arrhythmia* melalui analisis sinyal Elektrokardiogram (ECG) **memiliki** **peran yang sangat penting dalam upaya mengurangi** risiko kematian akibat henti jantung mendadak di kemudian hari (Sannino & De Pietro, 2021). ECG sendiri merupakan alat diagnostik yang cepat, murah, dan non-invasif, menjadikannya metode yang banyak digunakan untuk mendiagnosis berbagai jenis *Arrhythmia* (Acharya et al., 2017). Meskipun demikian, diagnosis *Arrhythmia* secara manual oleh kardiolog memiliki keterbatasan yang signifikan. Proses ini membutuhkan keahlian tinggi dan seringkali rentan terhadap pengaruh *noise* atau gangguan pada sinyal ECG, serta sifat acak dari kemunculan *Arrhythmia* (Acharya et al., 2017). Faktor-faktor ini dapat menyebabkan misdiagnosis atau kesalahan interpretasi, yang pada gilirannya dapat menunda intervensi medis yang krusial.

Mengingat tingginya angka mortalitas yang terkait dengan penyakit kardiovaskular, tantangan dalam mengklasifikasikan sinyal ECG ke dalam kondisi jantung spesifik mendorong pengembangan metode otomatis yang lebih akurat dan efisien (Nab, 2023). Kontras yang jelas antara metode diagnosis manual yang rentan terhadap kesalahan dan kebutuhan mendesak akan sistem otomatis yang akurat ini membentuk justifikasi kuat untuk pendekatan berbasis Artificial Intelligence (AI). Pendekatan ini secara efektif merumuskan masalah inti yang dapat diatasi oleh penelitian di bidang ini. **Dalam** **beberapa tahun terakhir**, teknologi Artificial Intelligence (AI), khususnya *Deep Learning* (DL), telah menunjukkan perkembangan pesat dan aplikasi yang luas dalam analisis sinyal biomedis (Acharya et al., 2017; Ahmed et al., 2023; Guerra et al., 2025). DL menawarkan alternatif yang jauh lebih baik untuk klasifikasi yang cepat dan otomatis dibandingkan metode tradisional (Ahmed et al., 2023; Nab, 2023). Kemampuan DL untuk secara otomatis mengekstraksi fitur-fitur penting dan belajar mandiri dari data mentah ECG memungkinkan deteksi pola halus yang mungkin terlewatkan oleh

pengamatan manusia (Ahmed et al., 2023; Nab, 2023). Selain itu, model DL mampu menangani *dataset* besar dan bising secara efektif, menjadikannya solusi yang menjanjikan untuk tantangan diagnosis *Arrhythmia* (Ahmed et al., 2023). Penggunaan AI dan DL dalam konteks ini bukan hanya sekadar mengikuti tren teknologi, melainkan merupakan solusi fundamental yang mengatasi keterbatasan diagnosis manual, menandai pergeseran paradigma dari rekayasa fitur manual ke ekstraksi fitur otomatis, yang secara signifikan dapat meningkatkan efisiensi dan akurasi diagnostik. Berdasarkan uraian di atas, penelitian ini mengkaji penerapan *Convolutional Neural Network 1D* pada *dataset* MIT-BIH yang telah dimodifikasi untuk hanya berisi satu detak per data (*detak tunggal*) dan kemudian mengklasifikasikannya menjadi hanya Normal dan Abnormal.

Penelitian ini termasuk dalam kategori penelitian terapan di bidang *Artificial Intelligence* dan *Biomedical Engineering*, khususnya dalam pengembangan sistem *Computer-Aided Diagnosis* (CAD) untuk *Arrhythmia* jantung. Mengingat tingginya akurasi yang telah dicapai oleh model *Deep Learning* pada *dataset* ini untuk klasifikasi biner, ide penelitian ini sangat relevan dan memiliki potensi besar untuk validasi ulang serta pengembangan aplikasi praktis dalam diagnosis medis.

3.2 Rumusan masalah

Berdasarkan latar belakang yang telah diuraikan, maka rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana proses pengumpulan, modifikasi, dan persiapan data sinyal ECG dari dataset MIT-BIH dapat dilakukan untuk membentuk data detak jantung tunggal yang siap digunakan dalam pelatihan model deep learning?
2. Bagaimana merancang arsitektur model *Convolutional Neural Network 1D* (1D-CNN) yang efektif untuk klasifikasi sinyal ECG menjadi dua kelas: Normal dan Abnormal?
3. Bagaimana pengaruh strategi preprocessing seperti penghapusan *outlier*, penyeimbangan kelas, *clustering* (K-Means), dan reduksi dimensi (PCA) terhadap kualitas dan performa dataset untuk klasifikasi biner?
4. Bagaimana strategi segmentasi sinyal ECG berbasis R-peak detection dapat membantu membentuk input yang fisiologis dan konsisten untuk model CNN?
5. Bagaimana performa model CNN 1D yang dikembangkan ketika dievaluasi menggunakan metrik akurasi, *precision*, *recall*, *F1-score*, dan AUC-ROC, baik terhadap data bersih (*clean evaluation set*) maupun data mentah (*prediction dataset*)?

1.3 Hipotesis

Model *Convolutional Neural Network ID* yang dilatih pada representasi detak jantung tunggal dari dataset MIT-BIH yang dimodifikasi akan mampu mengklasifikasikan detak jantung sebagai Normal atau Abnormal dengan tingkat akurasi dan kinerja (*precision*, *recall*, *F1-score*, dan *Area Under the Receiver Operating Characteristic Curve (AUC-ROC)*) yang tinggi, sebanding atau bahkan melampaui hasil penelitian terdahulu dalam klasifikasi biner detak jantung.³

1.4 Ruang lingkup penelitian

Penelitian ini memiliki batasan-batasan yang jelas untuk menjaga fokus dan ketercapaian tujuan. Ruang lingkup penelitian ini meliputi:

1.4.1. Dataset : Penelitian ini akan menggunakan ⁸⁸ *MIT-BIH Arrhythmia Database*(Ahmed et al., 2025; Nab, 2024; Moody & Mark, 2001). Data akan di proses untuk memastikan satu detak jantung, berpusat pada R-peak dan memiliki ukuran window yang konsisten(Ahmed et al., 2023).

1.4.2. Fokus klasifikasi : Klasifikasi akan difokuskan pada masalah biner, yaitu membedakan detak jantung Normal dari detak jantung Abnormal. Semua jenis *Arrhythmia* selain Normal akan dikelompokkan ke dalam kategori Abnormal (Nab, 2024; Panwar et al., 2025).

1.4.3. Metode : Implementasi dan evaluasi akan dilakukan menggunakan arsitektur *Convolutional Neural Network ID*. Model akan dilatih dan dievaluasi dengan mempertimbangkan praktik terbaik seperti *stratified splitting* dan penanganan ketidakseimbangan kelas (*class-weighting* atau *weighted sampling*) (Ahmed et al., 2023; Nab, 2023).

1.4.4. Aspek yang tidak dibahas : Penelitian ini tidak akan membahas deteksi atau klasifikasi *Arrhythmia* multi-kelas yang lebih spesifik (misalnya, membedakan *Supraventricular Ectopic* dari *Ventricular Ectopic* secara terpisah), pengembangan model untuk perangkat keras *real-time* yang spesifik, atau analisis fitur *time-frequency* yang lebih kompleks(Sannino & De Pietro, 2021). Fokus utamanya adalah validasi kinerja model *ID-CNN* untuk klasifikasi biner detak jantung tunggal. Pembatasan ruang lingkup secara jelas (apa yang dilakukan dan apa yang tidak) sangat penting untuk menjaga fokus penelitian. Dengan menyebutkan apa yang *tidak* dibahas, peneliti menunjukkan pemahaman tentang kompleksitas bidang dan memilih untuk fokus pada aspek yang dapat dikelola dan relevan dengan tujuan utama.

7 1.5 Tujuan dan manfaat penelitian

1.5.1 Tujuan penelitian

Tujuan yang ingin dicapai dalam penelitian ini adalah:

1. Mengembangkan dan mengimplementasikan model *Convolutional Neural Network 1D* untuk klasifikasi detak jantung Normal dan Abnormal dari dataset MIT-BIH yang telah dimodifikasi.
2. Melatih dan mengoptimalkan model *1D-CNN* menggunakan teknik pra-pemrosesan data yang sesuai, termasuk segmentasi detak jantung tunggal dan penanganan ketidakseimbangan kelas.
3. Mengevaluasi kinerja model *1D-CNN* dalam klasifikasi biner detak jantung menggunakan metrik evaluasi standar seperti akurasi, ²⁸ *precision*, *recall* (*sensitivity*), *F1-score*, dan *Area Under the Receiver Operating Characteristic Curve (AUC-ROC)*.

Tujuan-tujuan ini dirumuskan secara spesifik dan terukur ("mengembangkan," "melatih," "mengevaluasi"), yang merupakan ciri khas tujuan penelitian yang baik. Hal ini secara langsung mengacu pada langkah-langkah metodologis yang akan diambil, memberikan kejelasan tentang apa yang ingin dicapai.

1.5.2 Manfaat penelitian

Penelitian ini diharapkan dapat memberikan manfaat sebagai berikut:

1. **Bagi ilmu pengetahuan :** Penelitian ini diharapkan dapat memberikan validasi empiris lebih lanjut mengenai efektivitas *Convolutional Neural Network 1D* dalam klasifikasi biner detak jantung tunggal pada dataset ECG yang kompleks seperti MIT-BIH. Hasilnya dapat memperkaya literatur ilmiah terkait aplikasi *Deep Learning* dalam analisis sinyal biomedis dan menjadi referensi bagi penelitian serupa di masa mendatang.³
2. **Bagi teknologi :** Kontribusi penelitian ini dapat menjadi dasar **bagi pengembangan sistem** diagnosis *Arrhythmia* jantung **otomatis** yang lebih efisien dan akurat. Model yang dikembangkan berpotensi diintegrasikan ke dalam perangkat medis atau aplikasi *telemedicine* untuk skrining awal atau pemantauan jarak jauh, yang krusial untuk memberikan peringatan dan intervensi tepat waktu (Panwar et al., 2025; Nehru Institute of Technology et al., 2025).
3. **Bagi praktisi medis :** Sistem klasifikasi otomatis yang akurat dapat mendukung

tenaga medis dalam proses skrining awal dan diagnosis *Arrhythmia*, mengurangi beban kerja, dan meminimalkan potensi kesalahan diagnosis manual, sehingga memungkinkan intervensi dini dan peningkatan kualitas perawatan pasien (Ahmed et al., 2023; Sannino & De Pietro, 2021; Panwar et al., 2025).

Manfaat penelitian diuraikan secara multi-dimensi (ilmu, teknologi, praktisi). Ini menunjukkan pemahaman yang komprehensif tentang dampak penelitian, dari kontribusi teoretis hingga aplikasi praktis di dunia nyata, meningkatkan nilai dan relevansi studi.

1.6 Sistematika penulisan

Sistematika penulisan pada laporan penelitian ini terbagi menjadi 5 bab, yang kemudian masing-masing dibahas lebih detail dalam beberapa sub-bab. Berikut merupakan sistematisasi dari masing-masing bab beserta keterangannya :

Bab I Pendahuluan

Bab ini menguraikan latar belakang penelitian, termasuk tinjauan pustaka (*state of the art*) mengenai klasifikasi *Arrhythmia* dengan Deep Learning pada dataset MIT-BIH. Selanjutnya, bab ini merumuskan masalah, hipotesis, ruang lingkup, tujuan dan manfaat, metode penelitian secara umum, serta sistematika penulisan laporan.

Bab II Tinjauan Pustaka

Bab ini akan menyajikan landasan teori yang relevan, membahas secara lebih mendalam konsep Elektrokardiogram (ECG), *Arrhythmia* jantung, dasar-dasar Deep Learning, Convolutional Neural Network (CNN) 1D, serta dataset MIT-BIH *Arrhythmia*.

Bab III Metode Penelitian

Bab ini menjelaskan secara rinci tahapan penelitian yang dilakukan, mulai dari pengumpulan dan pra-pemrosesan data, perancangan arsitektur model 1D-CNN, proses pelatihan dan validasi, hingga prosedur evaluasi kinerja model.

Bab IV Hasil dan Pembahasan

Bab ini menyajikan hasil eksperimen yang diperoleh dari implementasi model, termasuk metrik kinerja, confusion matrix, dan kurva AUC-ROC. Hasil akan dianalisis dan dibahas secara komprehensif, membandingkan dengan hipotesis dan penelitian terdahulu.

Bab V Kesimpulan dan Saran

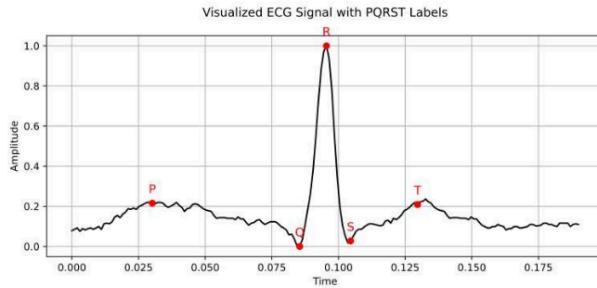
Bab terakhir ini merangkum temuan utama penelitian, menarik kesimpulan berdasarkan hasil yang diperoleh, serta memberikan saran untuk penelitian lanjutan.

BAB 2

TINJAUAN REFERENSI

2.1 Elektrokardiogram

Elektrokardiogram (EKG) adalah sinyal biologis yang merekam aktivitas listrik dari jantung melalui elektroda di kulit (Ashley & Niebauer, 2004). Sinyal EKG terdiri dari 3 gelombang utama, seperti yang ditunjukkan pada **Gambar 2.1**, yaitu gelombang P, yang merepresentasikan depolarisasi atrium, gelombang QRS, yang merepresentasikan depolarisasi ventrikel, dan gelombang T, yang merepresentasikan repolarisasi ventrikel. Sinyal EKG ini memiliki rentang frekuensi sekitar 0,05 Hz - 1000 Hz dan rentang listrik sekitar 1 mV - 10 mV secara normal (Velayudhan & Peter, 2016).



Gambar 2.1 Sinyal Elektrokardiogram

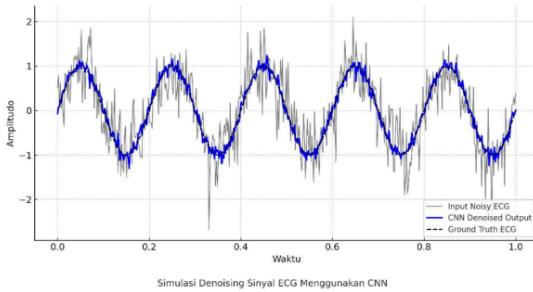
Mungkin terdapat sinyal yang tidak diinginkan atau suara bising yang dapat digabungkan dengan sinyal EKG yang sebenarnya selama perekaman. Derau ini harus dihilangkan, jika tidak, maka akan menyebabkan masalah analisis yang dapat menyebabkan diagnosis yang salah. Derau itu sendiri memiliki karakteristik frekuensi, sehingga dengan menghilangkan atau melewatkannya rentang frekuensi tertentu akan menghasilkan sinyal EKG yang sebenarnya.

2.2 Denoising dalam pemrosesan sinyal ECG

Dalam pengolahan sinyal biomedis, khususnya sinyal Electrocardiogram (ECG), keberadaan dari noises merupakan salah satu tantangan utama yang dapat mempengaruhi akurasi dari analisis. Noise ini dapat berasal dari berbagai sumber seperti baseline wander, powerline interface, Gerakan pasien maupun aktivitas dari otot. Oleh karena itu, tahapan denoising ini menjadi Langkah esensial pada pra-pemrosesan sinyal ECG sebelum dilakukan pelatihan model CNN. Dalam Konteks

penelitian ini, proses denoising tidak dilakukan melalui metode eksplisit namun dilakukan melalui pendekatan yang structural dan segmentatif. Data ECG yang digunakan bersumber dari MIT-BIH Arrhythmia Database yang telah dianotas oleh ahli dan hanya mencakup sinyal yang relevan dengan peristiwa detak jantung. Proses seperti trimming Panjang sinyal normal, pemindahan label ke posisi akhir dan shifting secara tidak langsung berkontribusi dalam menghilangkan bagian sinyal yang mengandung noise, seperti area sebelum dan sesudah terdeteksi seperti pada **Gambar 94**.

2.2



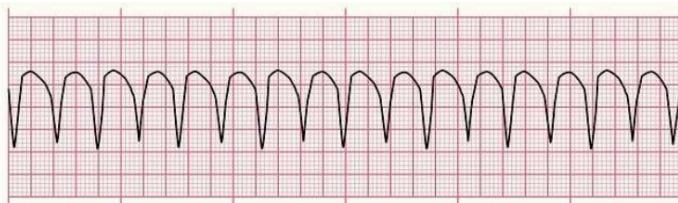
Gambar 2.2 Denoising ECG

Strategi ini termasuk dalam pendekatan *implicit noise reduction*, yaitu penghapusan *noise* melalui seleksi segmen dan normalisasi struktur data alih-alih melalui filter matematis. Hal ini terbukti efektif karena model deep learning, khususnya *hybrid CNN-LSTM*, sangat sensitif terhadap variasi struktural maupun numerik pada input data (Faust et al., 2018). Dengan demikian, meskipun tidak menggunakan teknik denoising eksplisit, penelitian ini telah menerapkan prinsip denoising secara adaptif melalui strategi segmentasi dan pemangkasan berbasis anotasi yang memperkuat robustness model terhadap variasi sinyal yang berasal dari noise.

2.3 Deteksi *Arrhythmia*, Sinyal Abnormal dan Variabilitas Sinyal

Arrhythmia adalah kondisi abnormal dari ritme jantung yang dapat mengancam jiwa, seperti takikardia ventrikular (VT) pada **Gambar 3**, fibrilasi ventrikular (VF) pada **Gambar 4**, dan fibrilasi atrium (AF) pada **Gambar 5**. Kondisi ini menyebabkan denyut jantung menjadi terlalu cepat, terlalu lambat, atau tidak teratur. *Arrhythmia* terjadi ketika impuls listrik yang mengatur detak jantung tidak bekerja dengan baik, sehingga menyebabkan aktivitas elektrik jantung menjadi kacau (Zipes & Jalife, 2013).

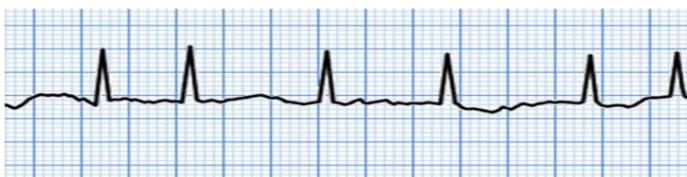
Menurut *American Heart Association* (AHA), *arrhythmia* merupakan penyebab utama dari berbagai komplikasi kardiovaskular, dan deteksi dini melalui ECG menjadi komponen penting dalam pencegahan gagal jantung dan stroke (AHA, 2021).



Gambar 2.3 Takikardia Ventrikel (VT)



Gambar 2.1 fibrilasi ventrikular (VF)



Gambar 2.2 fibrilasi atrium (AF)

Dalam konteks klasifikasi sinyal ECG, seluruh bentuk detak jantung abnormal dikategorikan sebagai kelas "1" atau *arrhythmia*, sedangkan detak jantung normal diklasifikasikan sebagai "0". Klasifikasi biner ini disesuaikan dengan pendekatan machine learning yang digunakan dalam penelitian ini agar lebih efisien dalam pemodelan dan analisis. Pengkategorian seluruh jenis kelainan detak jantung ke dalam satu label umum (*arrhythmia*) dianggap cukup representatif pada tahap awal klasifikasi, terutama saat model difokuskan pada deteksi keberadaan kelainan, bukan

spesifikasinya (Faust et al., 2018). Dalam konteks klasifikasi sinyal ECG, seluruh bentuk detak jantung abnormal dikategorikan sebagai kelas "1" atau *arrhythmia*, sedangkan detak jantung normal diklasifikasikan sebagai "0". Klasifikasi biner ini disesuaikan dengan pendekatan machine learning yang digunakan dalam penelitian ini agar lebih efisien dalam pemodelan dan analisis. Pengkategorian seluruh jenis kelainan detak jantung ke dalam satu label umum (*arrhythmia*) dianggap cukup representatif pada tahap awal klasifikasi, terutama saat model difokuskan pada deteksi keberadaan kelainan, bukan spesifikasinya (Faust et al., 2018).

2.4 Heart Rate Variability⁶⁹

Heart Rate Variability (HRV) adalah ukuran fluktuasi waktu antara dua detak jantung berturut-turut, yang biasanya dihitung dari interval RR pada sinyal ECG. HRV mencerminkan keseimbangan antara sistem saraf simpatik dan parasimpatik, dan sering digunakan sebagai indikator kesehatan kardiovaskular serta stres fisiologis (Shaffer & Ginsberg, 2017). Secara umum, HRV dapat dianalisis melalui tiga pendekatan utama: domain waktu (misalnya SDNN, RMSSD), domain frekuensi (misalnya LF¹⁶, HF¹⁶, LF/HF ratio), dan domain non-linear (misalnya *Poincaré plot*, *entropy*). Dalam penelitian berbasis *machine learning*, fitur-fitur HRV ini sering digunakan untuk membedakan kondisi detak jantung normal dan abnormal (Acharya et al., 2006). Fitur HRV yang rendah biasanya menunjukkan kondisi abnormal seperti *arrhythmia* atau stres jantung, sementara nilai HRV yang tinggi menandakan sistem otonom yang sehat dan adaptif. Dalam konteks penelitian ini, HRV memiliki relevansi sebagai sinyal pembeda yang dapat digunakan sebagai input untuk model CNN atau LSTM, atau sebagai penanda penurunan kualitas ritme jantung.

2.5 Dataset MIT-BH *Arrhythmia*⁴²

MIT-BIH *Arrhythmia* Database merupakan salah satu dataset benchmark paling komprehensif dan banyak digunakan dalam penelitian analisis sinyal elektrokardiogram (ECG). Dataset ini dikembangkan oleh Beth Israel Hospital bekerja sama dengan Massachusetts Institute of Technology (MIT) dan tersedia secara publik melalui platform PhysioNet dan Kaggle (Goldberger et al., 2000; Yoon, 2023). Dataset ini terdiri dari 48 rekaman ECG dua channel berdurasi sekitar 30 menit, yang direkam dari 47 pasien rawat jalan dan rumah sakit. Setiap rekaman memiliki dua lead: MLII (Modified Lead II) dan V1, serta disampling pada frekuensi 360 Hz. Rekaman ini telah dianotasi secara manual oleh ahli jantung, mencakup lebih dari 100.000 detak jantung

yang diklasifikasikan ke dalam lebih dari 15 tipe detak, seperti detak **normal (N)**, **premature ventricular contraction (V)**, **atrial premature beat (A)**, dan lainnya.

Struktur data terdiri dari:

1. *Signal Time Series*: data numerik sinyal ECG dalam satuan milivolt.
2. *Sample Index*: titik waktu untuk setiap anotasi detak.
3. *Annotation Label*: label untuk tiap detak, sesuai klasifikasi **AAMI (Association for the Advancement of Medical Instrumentation)**.

Dalam penelitian ini, dataset digunakan dalam format yang telah disederhanakan dan diproses ulang oleh Taejoong Yoon melalui Kaggle, yang menggabungkan sinyal berdurasi pendek (segmentasi) dan mengelompokkan tipe detak jantung menjadi dua kelas utama, yaitu:

1. Label 0: Detak jantung normal
2. Label 1: Detak jantung abnormal (*arrhythmia*)

Penggunaan dataset ini sangat sesuai untuk pengembangan dan evaluasi sistem diagnosis otomatis berbasis machine learning karena:

1. Anotasi dilakukan secara manual oleh ahli jantung
2. Sinyal tersedia dalam format digital dan dapat diakses
3. Mencakup variasi besar dalam kondisi fisiologis dan patologis

Dataset ini juga dilengkapi dengan metadata tambahan seperti jenis kelamin pasien, lead yang digunakan, dan waktu perekaman. Dengan demikian, MIT-BIH *Arrhythmia* Database tidak hanya memberikan sinyal ECG mentah, tetapi juga konteks klinis yang dapat membantu dalam interpretasi hasil klasifikasi dan generalisasi model terhadap populasi yang lebih luas. Dataset versi Kaggle oleh Taejoong Yoon (2023) menyediakan data ini dalam format yang lebih mudah diakses, dengan pembagian detak jantung menjadi normal dan abnormal berdasarkan tipe anotasi. Dataset ini sangat berguna untuk melatih dan mengevaluasi model machine learning karena mengandung variasi besar dalam kondisi kardiak.

2.6 Modifikasi Data

Setelah data terkumpul, dilakukan proses modifikasi guna membentuk struktur data yang siap digunakan untuk pelatihan model machine learning. Salah satu tahapan

utama adalah pembentukan sub-dataset dengan mengambil sampel rekaman secara acak dari database besar untuk menjaga keberagaman representasi sinyal. Kemudian, dilakukan proses segmentasi sinyal menjadi fixed-length windows yang merepresentasikan satu siklus detak jantung. Proses ini merujuk pada studi Murali et al. (2025), yang menyarankan pemotongan sinyal ECG berdasarkan jarak antar R-peak atau menggunakan pendekatan sliding window dengan jumlah sampel konstan seperti 256 titik. Tujuan dari segmentasi ini adalah untuk menciptakan representasi spasial-temporal yang konsisten untuk setiap heartbeat cycle, mengingat variasi panjang sinyal dapat mengganggu pelatihan model konvolusional.

Tahap selanjutnya adalah *reclassification* label dari bentuk multikategori menjadi dua kelas biner yaitu Normal dan Abnormal. Panwar et al. (2025) menyebutkan bahwa pendekatan klasifikasi biner tidak hanya menyederhanakan kompleksitas model, tetapi juga lebih efisien pada aplikasi real-time dan perangkat portabel. Semua kategori ⁸⁰ arrhythmia seperti *Premature Ventricular Contraction (PVC)*, *Atrial Fibrillation (AF)*, dan *Ventricular Tachycardia (VT)* diklasifikasikan ke dalam kelas Abnormal. Hal ini juga bertujuan mempermudah penilaian performa awal model sebelum dilakukan klasifikasi lanjutan secara multi-kelas. Sebagai langkah validasi kemampuan generalisasi model, sebagian kecil data yang belum dibersihkan secara ekstensif juga disisihkan sebagai prediction dataset, yang akan digunakan untuk menguji performa model terhadap data noisy yang lebih menyerupai kondisi di lapangan.

2.7 Persiapan data

Persiapan data dimulai dengan eksplorasi data ⁷⁹ menggunakan metode exploratory data analysis (EDA) untuk memahami distribusi data, mendeteksi nilai kosong, dan mengidentifikasi outlier. (Zahid et al., 2020) menunjukkan bahwa *outlier* pada data ECG dapat berdampak besar terhadap performa model deteksi, terutama dalam hal sinyal ekstrem akibat gangguan perangkat keras atau noise. Oleh karena itu, dilakukan pembersihan dengan teknik Z-score *normalization*. Sedangkan untuk menghitung Z-score itu sendiri menggunakan persamaan (1):

$$z = \frac{x - \mu}{\sigma} \quad (1)$$

⁸⁵ di mana x merupakan nilai amplitudo sinyal, μ adalah rata-rata populasi, dan σ adalah standar deviasi. Nilai $Z > 3$ atau $Z < -3$ dikategorikan sebagai *outlier* dan dieliminasi. Untuk mengatasi ketidakseimbangan kelas (*class imbalance*) antara Normal dan

Abnormal, digunakan teknik *resampling* atau seleksi data terstratifikasi. (Alinsaif, 2024) menyarankan bahwa distribusi data yang tidak seimbang dapat menyebabkan model cenderung bias terhadap kelas mayoritas, sehingga proses *balancing* harus dilakukan sebelum pelatihan. Selain itu, dilakukan validasi terhadap keberagaman sinyal *arrhythmia* menggunakan analisis *K-Means Clustering*, guna memastikan bahwa data dalam kelas abnormal mencakup spektrum variasi yang luas. Fungsi objektif dari *K-Means* dapat dituliskan dengan **persamaan (2)**:

$$\arg \min_{\{c_1, c_2, \dots, c_k\}} \left\{ \sum_{i=1}^k \sum_{x \in c_i} \|x - \mu_i\|^2 \right\} \quad (2)$$

sdi mana C_i adalah cluster ke- i dan μ adalah centroid-nya pada rumus. Rumus *K-Means* tersebut merepresentasikan fungsi objektif yang bertujuan meminimalkan total kuadrat jarak antara tiap data dengan pusat klaster (*centroid*) tempat data tersebut berada. Dalam hal ini, x adalah titik data dan $\|x - \mu_i\|$ menunjukkan jarak Euclidean kuadrat. Semakin kecil nilai total fungsi tersebut, semakin kompak data dalam masing-masing klaster, menandakan bahwa proses pengelompokan telah berhasil mengidentifikasi struktur alami dalam data.. Terakhir, dilakukan *dimensionality reduction* menggunakan *Principal Component Analysis (PCA)* untuk mengekstraksi komponen utama dan mengurangi redundansi dimensi dengan **persamaan(3)**:

$$T = X \cdot W \quad (3)$$

di mana T adalah hasil transformasi, X adalah matriks data input, dan W adalah matriks *eigenvector* dari kovariansi X . PCA dinyatakan efektif (Eleyan & Alboghbaish, 2024) dalam meningkatkan efisiensi pelatihan model ECG dengan tetap mempertahankan informasi utama dari sinyal.

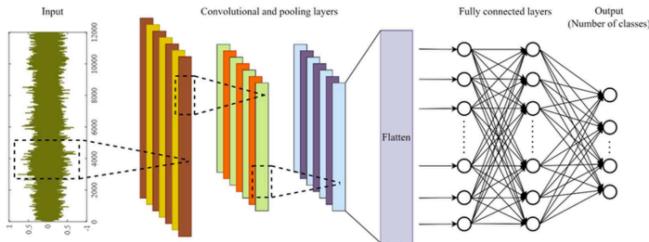
2.8 CNN dan Conv-1D

⁶³ *Convolutional Neural Network (CNN)* adalah salah satu jenis deep neural network yang menggunakan operasi linear matematika antar matriks yang disebut dengan *convolution* (Bayat et al., 2017). CNN dirancang untuk mendeteksi pola atau struktur spasial dari data dan telah menjadi metode utama dalam berbagai bidang seperti pengenalan pola (pattern recognition), klasifikasi sinyal, dan pengolahan citra medis. Aspek penting dari CNN adalah kemampuannya untuk melakukan reduksi parameter secara signifikan dibandingkan dengan *Artificial Neural Network (ANN)*, sehingga

menjadikan CNN lebih efisien dan unggul dalam mendekripsi fitur kompleks dari data masukan (Bayat et al., 2017). Arsitektur CNN terdiri dari beberapa layer konvolusi, aktivasi, pooling, dan fully connected yang saling terhubung, sehingga memungkinkan proses ekstraksi fitur secara bertingkat dari input mentah hingga representasi tingkat tinggi.

Berdasarkan dimensi input yang ditangani, CNN terbagi menjadi:

1. 1-D CNN untuk data sinyal dan deret waktu (time-series), seperti sinyal ECG, pengenalan suara (*voice recognition*), dan analisis teks.
2. 2-D CNN untuk data gambar atau peta fitur dua dimensi.
3. 3-D CNN untuk data spasio-temporal seperti video atau citra medis 3D (MRI, CT-scan).



Gambar 2.6 Arsitektur 1-D CNN

Dalam konteks penelitian ini, kami menggunakan 1-D CNN untuk menganalisis sinyal ECG satu dimensi dan contoh visualisasinya ada pada **Gambar 2.6**. Layer konvolusi satu dimensi (Conv1D) secara spesifik melakukan operasi konvolusi dengan cara menggeser kernel sepanjang dimensi waktu. Setiap kernel akan mengekstrak fitur lokal seperti pola QRS kompleks, gelombang P dan T. Dengan parameter seperti kernel size, stride, dan padding, struktur Conv1D dapat disesuaikan dengan panjang dan resolusi sinyal input. Penggunaan Conv1D pada model CNN terbukti efektif dalam mengekstraksi fitur spasial dari sinyal ECG.

2.9 Auto Encoder

Autoencoder merupakan jenis jaringan saraf tiruan yang digunakan untuk melakukan kompresi data (*encoding*) dan kemudian merekonstruksi kembali data tersebut (*decoding*) dengan tujuan mempertahankan informasi penting dari input awal.

Arsitektur *autoencoder* terdiri atas tiga bagian utama: *encoder*, *bottleneck (latent space)*, dan *decoder* (Hinton & Salakhutdinov, 2006). Dalam konteks sinyal ECG, *autoencoder* berguna untuk mengurangi dimensi data dan menghilangkan komponen yang tidak signifikan atau bersifat *noise*. Proses ini sangat membantu dalam ekstraksi fitur, terutama ketika sinyal mengandung fluktuasi kompleks akibat variasi fisiologis atau gangguan luar. Dengan menekan sinyal ke dalam representasi berdimensi rendah, *autoencoder* dapat memfasilitasi proses klasifikasi dan meningkatkan efisiensi komputasi. Dalam penelitian ini, *autoencoder* berperan sebagai tahap awal pra-pemrosesan untuk mendukung model CNN-LSTM. Representasi hasil encoder dapat digunakan sebagai input ke CNN atau digabungkan kembali ke struktur hybrid. *Autoencoder* juga dapat berfungsi untuk denoising sinyal ECG secara tidak langsung, karena ia belajar merekonstruksi sinyal ideal dari input yang mungkin tercampur noise. Penggunaan *autoencoder* pada sinyal fisiologis telah terbukti mampu meningkatkan akurasi klasifikasi dalam berbagai studi, termasuk klasifikasi *arrhythmia* dan deteksi serangan jantung (Zhao et al., 2019; Xiong et al., 2021).

2.10 Kinerja Model

Evaluasi kinerja merupakan elemen krusial dalam validasi model klasifikasi, khususnya dalam konteks medis seperti pendekripsi *arrhythmia* jantung dari sinyal elektrokardiogram (ECG). Model yang digunakan perlu dievaluasi secara menyeluruh agar tidak hanya akurat secara numerik, tetapi juga dapat diandalkan dalam skenario nyata, termasuk kasus dengan distribusi kelas yang tidak seimbang.

Matrik evaluasi yang digunakan untuk menilai performa kinerja model ini antara lain adalah:

1. Akurasi : Mengukur proporsi total prediksi yang benar. Meskipun umum digunakan, metrik ini kurang representatif pada dataset dengan distribusi kelas yang timpang (Luz et al., 2016).
2. Presisi : menunjukkan seberapa besar proporsi prediksi positif yang benar dari seluruh prediksi positif dan ditunjukkan dengan persamaan (4) :

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad (4)$$

Dimana *True Positive (TP)* adalah jumlah data positif yang berhasil diklasifikasikan dengan benar oleh model. *False Positive (FP)* adalah jumlah data negatif yang secara keliru diklasifikasikan sebagai positif oleh model.

3. *Recall (Sensitivity)* : mengukur seberapa jauh dan ⁴⁸ seberapa baik model dalam mendeteksi kasus positif yang sebenarnya ditunjukkan dengan **persamaan(5)**:

$$\text{Recall} = \frac{TP}{TP + FN} \quad (5)$$

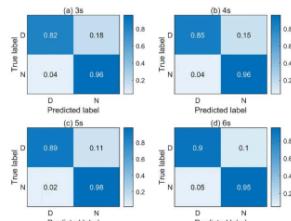
Dimana TP sudah dijelaskan pada poin bagian 2. Sedangkan untuk FN itu sendiri adalah *False Negative (FN)* dimana jumlah data positif yang salah itu diklasifikasikan sebagai negatif oleh model.

4. **F1-Score** : **F1-Score** ini adalah rata-rata dari harmonisasi presisi dan recall dan digunakan untuk evaluasi pada dataset yang tidak seimbang ditunjukkan dengan **persamaan(6)**:

$$F_1 = \frac{\frac{58}{2} \times (\text{Precision} \times \text{Recall})}{\text{Precision} + \text{Recall}} \quad (6)$$

5. *Confusion matrix*

Matriks ini menampilkan perbandingan antara prediksi dan kenyataan dalam empat komponen: true positives (TP), true negatives (TN), false positives (FP), dan false negatives (FN) ditunjukkan pada **Gambar 2.7**.



Gambar 2.7 Confusion Matrix

2.11 Related works

Penelitian ini bukanlah yang pertama yang mencoba memprediksi *arrhythmia* jantung. Sejumlah penelitian sebelumnya telah mengeksplorasi domain ini menggunakan berbagai teknik pembelajaran mesin, mulai dari jaringan saraf dasar hingga arsitektur yang lebih canggih seperti CNN-LSTM. Beberapa karya terkait ⁸⁴ ini dirangkum dalam **Tabel 2.1**.

Tabel 2.1 Related Works

Author	Description	Method	Dataset	Accuracy
(Ebrahimzadeh et al., 2014)	<i>Single patient's HRV and One minute prior VF</i>	Neural Network	Holter	99.7%
(Ebrahimzadeh et al., 2014)	<i>Single patient's HRV and three minutes prior VF</i>	Neural Network	Holter	90.3%
(Ebrahimzadeh et al., 2014)	<i>Single patient's HRV and four minutes prior VF</i>	Neural Network	Holter	83.9%
(Zheng et al., 2020)	<i>Classifying non-SCD</i>	CNN-LSTM	MIT-BIH	99%
(Warrick & Nabhan Homsi, 2017)	<i>Classifying non-SCD</i>	CNN-LSTM	Physionet Challenge 2017	83%
(Oh et al., 2018)	<i>Classifying non-SCD</i>	CNN-LSTM	MIT-BIH	99%
(Shi et al., 2019)	<i>Classifying non-SCD</i>	CNN- LSTM	MIT-BIH	98%

Sebagai contoh, Ibtehaz *et al.* (2019) melaporkan akurasi klasifikasi yang mengesankan, yaitu hampir 99% ketika membedakan antara kejadian fibrilasi ventrikel (VF) dan non-VF. Namun, model mereka secara khusus dirancang untuk mendekripsi kejadian hanya beberapa detik sebelum terjadinya kematian jantung mendadak (SCD), sehingga membatasi kesempatan untuk intervensi medis yang tepat waktu. Peneliti lain, termasuk Ebrahimzadeh *et al.* (2014), Lee *et al.* (2016), dan Joo *et al.* (2010),

mengadopsi metodologi prapemrosesan dan pemilihan fitur yang serupa. Mereka terutama berfokus pada indikator *Heart Rate Variability* (HRV), khususnya interval RR, yang mewakili waktu antara puncak R yang berurutan dalam sinyal EKG. Ukuran statistik seperti rata-rata dan deviasi standar interval RR, bersama dengan variabilitas periode pernapasan, diekstraksi dan dievaluasi menggunakan nilai-p untuk menentukan signifikansi statistiknya. Hanya fitur yang paling berpengaruh yang dipilih sebagai masukan untuk masing-masing model. Perbedaan utama di antara penelitian-penelitian ini terletak pada arsitektur jaringan saraf yang digunakan. Lee *et al.* (2016) mengimplementasikan jaringan saraf tiruan dengan satu dan dua lapisan tersembunyi, masing-masing terdiri dari lima neuron. Sebaliknya, Joo *et al.* (2010) menggunakan arsitektur yang lebih dalam dengan dua lapisan tersembunyi, masing-masing berisi 25 neuron, yang menghasilkan peningkatan waktu pelatihan dan kompleksitas komputasi. Sementara itu, Ebrahimzadeh *et al.* (2014) membandingkan kinerja Multi-Layer Perceptron (MLP) dengan pengklasifikasi K-Nearest Neighbor (KNN).

Pendekatan alternatif diusulkan oleh Farhadi *et al.* (2017), yang menggunakan Algoritma Genetika (GA) sebagai teknik optimasi. Daripada mengonfigurasi arsitektur model secara manual, GA digunakan untuk secara otomatis mengidentifikasi kombinasi fitur dan struktur jaringan yang optimal, menggunakan set data yang sama dan fitur berbasis HRV. Khususnya, metode ini memungkinkan pengecualian fitur-fitur domain frekuensi, yang sering kali sulit untuk diekstraksi dan diinterpretasikan. Lebih lanjut, Rajput *et al.* (2019) menekankan bahwa sinyal EKG mentah dapat secara efektif dimasukkan ke dalam model pembelajaran mendalam, sehingga memungkinkan model untuk mempelajari fitur-fitur yang relevan secara mandiri tanpa memerlukan rekayasa fitur secara manual. Hal ini mendukung gagasan tentang jalur pembelajaran ujung ke ujung untuk deteksi *arrhythmia*. Dalam penelitian lain, Verma dan Dong (2016) mencapai lebih dari 94% akurasi dalam membedakan ritme VF dari non-VF menggunakan fitur yang diturunkan dari HRV dan pengklasifikasi hutan acak. Berdasarkan upaya ini, penelitian saat ini bertujuan untuk memasukkan takikardia ventrikel (VT) sebagai kelas tambahan yang akan diprediksi. Secara kolektif, model CNN-LSTM telah menunjukkan efektivitas yang substansial dalam mendeteksi dan mengklasifikasikan irama jantung. Meskipun sebagian besar penelitian sebelumnya memanfaatkan arsitektur ini untuk ekstraksi fitur dan klasifikasi VT/VF, mereka umumnya tidak menyertakan komponen prediksi atau peramalan sehingga membatasi

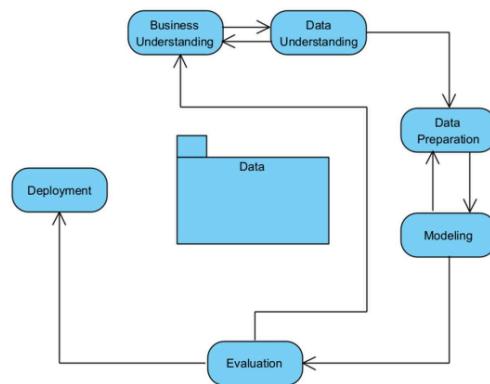
potensi intervensi dini. Sebagai tanggapan, penelitian ini mengusulkan integrasi CNN dan LSTM untuk tidak hanya mengklasifikasikan tetapi juga meramalkan kemungkinan terjadinya VF atau VT dan memberi waktu untuk tindakah pencegahan.

61 BAB 3

METODE PENELITIAN

3.1 Pendekatan penelitian

Penelitian ini mengadopsi pendekatan kuantitatif dengan desain eksperimental, mengikuti kerangka kerja CRISP-DM (*Cross-Industry Standard Process for Data Mining*) pada Gambar 6.. CRISP-DM adalah model standar industri yang menyediakan panduan terstruktur untuk proyek berbasis data, memastikan pendekatan yang sistematis dan iteratif. Kerangka ini dipilih karena kemampuannya untuk mengelola kompleksitas proyek *deep learning* secara efektif, dari pemahaman masalah bisnis hingga implementasi solusi. Enam fase utama dalam CRISP-DM, yang akan diterapkan dalam penelitian ini pada **Gambar 3.1**, meliputi:



Gambar 3.1 CRISP-DM Model

Pendekatan penelitian ini dimulai dengan tahap *Business Understanding*, di mana tujuan utama dari penelitian dipahami secara mendalam dari perspektif domain medis, khususnya dalam konteks kebutuhan akan diagnosis *Arrhythmia* yang akurat. Diagnosis yang tepat dan cepat terhadap *cardiac Arrhythmia* sangat penting, mengingat keterkaitannya dengan risiko *sudden cardiac arrest* dan *ischemic stroke* (Al-Zaiti et al., 2020). Pemahaman yang komprehensif terhadap latar belakang klinis menjadi dasar dalam merancang sistem pendekatan berbasis *machine learning* yang dapat mendukung keputusan medis secara objektif dan efisien.

Tahap selanjutnya adalah *Data Understanding*, yang mencakup proses awal pengumpulan data *electrocardiogram (ECG)* dan eksplorasi terhadap karakteristik sinyal yang dikumpulkan. Proses ini bertujuan untuk mengidentifikasi struktur data, distribusi nilai, serta mendeteksi potensi masalah seperti *missing values*, *signal noise*, atau gangguan artefak yang mungkin mempengaruhi kualitas data (Zahid et al., 2020). Selain itu, dilakukan juga pengamatan terhadap label anotasi dan korelasinya dengan jenis-jenis *Arrhythmia*.

Setelah karakteristik data dipahami, proses dilanjutkan ke tahap *Data Preparation*. Pada fase ini, dilakukan serangkaian *pre-processing* seperti *signal segmentation* berdasarkan titik *R-peak*, *normalization* untuk memastikan keseragaman skala amplitudo, serta penanganan *class imbalance* dengan metode *oversampling* atau *undersampling* untuk menjaga proporsi representatif antar kelas (Alinsaif, 2024). Tujuan utama dari tahap ini adalah untuk menghasilkan data bersih dan siap pakai dalam pelatihan model *deep learning*.

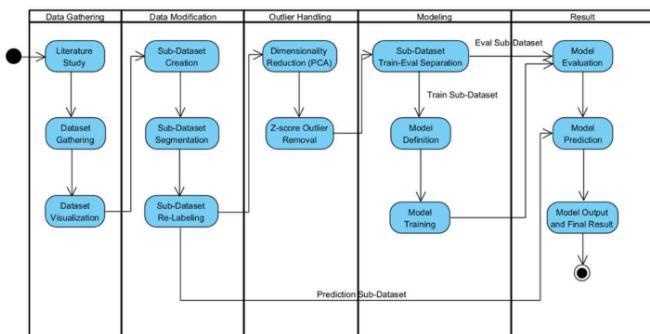
Tahap krusial berikutnya adalah *Modeling*, di mana arsitektur *deep neural network* yang dipilih adalah *1D-Convolutional Neural Network (1D-CNN)*. Arsitektur ini telah terbukti efektif dalam menangkap pola lokal dari sinyal sekuensial seperti ECG karena kemampuannya dalam mengenali fitur spasial-temporal dari sinyal berdimensi satu (Yildirim, 2018). Pada fase ini juga dilakukan penentuan *hyperparameters* seperti jumlah *filters*, ukuran *kernel*, *learning rate*, dan jumlah *epochs* untuk memastikan model memiliki *generalization performance* yang optimal.

Setelah model selesai dilatih, dilakukan proses *Evaluation* terhadap performa model menggunakan metrik evaluasi seperti *Precision*, *Recall*, *F1-Score*, *Accuracy*, dan *Area Under the Curve - Receiver Operating Characteristic (AUC-ROC)*. Evaluasi ini bertujuan untuk menilai seberapa baik model dalam membedakan antara sinyal *normal* dan *abnormal*, serta memastikan bahwa model tidak overfitting terhadap data latih (Eleyan & Alboghaish, 2024). Meskipun implementasi penuh sistem *real-time* tidak menjadi fokus utama dalam penelitian ini, tahap akhir yaitu *Deployment* tetap dibahas sebagai bagian dari proyeksi aplikasi nyata dari model yang dikembangkan. Diskusi pada tahap ini mencakup kemungkinan integrasi sistem ke dalam perangkat *wearable* atau sistem monitoring rumah sakit, serta tantangan dan peluang dalam penerapan model di lingkungan klinis maupun non-klinis (Panwar et al., 2025).

3.2 Tahapan penelitian

Proses penelitian akan dibagi menjadi beberapa tahapan utama yang terstruktur, dimulai dari persiapan data hingga evaluasi model, seperti yang digambarkan pada ⁷⁸

Gambar 3.2.



Gambar 3.2 Tahapan penelitian

Penelitian ini dirancang dengan pendekatan sistematis yang terdiri dari lima fase utama yang saling mendukung, yaitu: perolehan data, modifikasi data, persiapan data, pelatihan model, serta evaluasi hasil. Seluruh alur kerja ini bertujuan untuk membangun sistem klasifikasi *arrhythmia* jantung berbasis sinyal ECG menggunakan metode pembelajaran mendalam dengan klasifikasi dua kelas (normal vs abnormal). Pada tahap awal, dilakukan eksplorasi literatur untuk menelusuri metode dan praktik terbaik dalam deteksi *arrhythmia* berbasis sinyal fisiologis. Sumber rujukan mencakup jurnal akademik, dokumen konferensi, hingga repositori publik seperti PhysioNet dan Kaggle (Goldberger et al., 2000; Yoon, 2023). Berdasarkan hasil kajian tersebut, MIT-BIH *Arrhythmia* Database dipilih sebagai dataset utama karena telah diakui secara luas dalam studi klinis dan memiliki dokumentasi yang baik (Moody & Mark, 2001).

Tahapan berikutnya berfokus pada proses penyesuaian struktur data agar kompatibel dengan kebutuhan pemodelan deep learning. Beberapa rekaman ECG dipilih secara acak namun mewakili variasi sinyal dan distribusi label yang seimbang. Sinyal berdurasi panjang kemudian dipotong menjadi segmen-semen pendek yang mencerminkan satu siklus jantung, dengan pusat pada titik R sebagai referensi fisiologis utama. Proses ini dilakukan agar masukan model memiliki struktur temporal

yang konsisten (Acharya et al., 2017). Selain itu, label awal yang terdiri dari banyak kelas dikonsolidasikan menjadi dua kategori utama: normal dan abnormal, untuk menyederhanakan proses klasifikasi dan meningkatkan efisiensi pembelajaran model (Panwar et al., 2025). Sebagai tambahan, disiapkan juga satu subset khusus yang berisi data prediksi acak yang tidak melalui tahap pra-pemrosesan penuh. Tujuan dari subset ini adalah untuk mengevaluasi kemampuan model dalam menghadapi data nyata yang tidak terstruktur atau mengandung noise (Faust et al., 2018).

Pada tahap persiapan data, dilakukan berbagai teknik eksplorasi dan pembersihan data. Analisis awal dilakukan melalui *exploratory data analysis* (EDA) guna meninjau distribusi fitur, mendeteksi nilai kosong, serta mengidentifikasi pola-pola data yang menyimpang (Tukey, 1977; Das & Behera, 2021). Data yang menunjukkan nilai ekstrem berdasarkan statistik Z-score (di luar ± 3 standar deviasi) dihapus dari dataset guna menghindari distorsi dalam proses pembelajaran (Iglewicz & Hoaglin, 1993). Komposisi kelas juga dianalisis, dan bila ditemukan ketimpangan jumlah antara kelas normal dan abnormal, diterapkan strategi penyeimbangan seperti *resampling* untuk menjaga netralitas pelatihan (He & Garcia, 2009). Guna memastikan bahwa sinyal dalam kelas abnormal tetap mencerminkan keragaman fisiologis, digunakan metode *K-Means Clustering* untuk memverifikasi keberagaman bentuk gelombang yang masih tersisa dalam dataset (Jain, 2010). Langkah lanjutan berupa reduksi dimensi dilakukan menggunakan PCA (Principal Component Analysis), yang digunakan untuk memahami struktur spasial data dan menyaring korelasi antar fitur dengan cara yang efisien (Jolliffe & Cadima, 2016; Abdi & Williams, 2010).

Pada fase pelatihan model, data dibagi ke dalam dua bagian utama: *training set* dan *evaluation set*, dengan pembagian stratified guna mempertahankan rasio kelas yang proporsional. Model utama yang diimplementasikan adalah 1D Convolutional Neural Network (1D-CNN), yang dirancang untuk mengekstraksi karakteristik lokal dari sinyal deret waktu seperti ECG. Struktur jaringan mencakup beberapa lapisan konvolusi dan pooling, diakhiri dengan lapisan fully-connected untuk klasifikasi akhir. Proses pelatihan dilakukan dalam beberapa epoch dengan optimasi menggunakan algoritma Adam dan fungsi aktivasi ReLU di lapisan tersembunyi serta sigmoid di output layer (Zhao et al., 2019; Hannun et al., 2019). Selain itu, checkpoint diterapkan selama pelatihan untuk menyimpan model dengan performa terbaik berdasarkan metrik validasi.

Fase akhir dalam metodologi adalah evaluasi kinerja model. Evaluasi dilakukan dalam dua skenario: pertama, menggunakan *evaluation set* yang telah melalui pra-pemrosesan lengkap, dan kedua, dengan *prediction dataset* yang tidak dibersihkan.³⁹ Performa model dinilai menggunakan metrik klasifikasi seperti akurasi, presisi, recall, F1-score, serta AUC-ROC untuk memberikan penilaian yang menyeluruh (Chicco & Jurman, 2020). Evaluasi ganda ini tidak hanya mengukur efektivitas model dalam kondisi ideal, tetapi juga menguji ketahanannya dalam menghadapi sinyal yang menyerupai kondisi nyata di lapangan.

3.3 Analisis dan perancangan model 1D-CNN

3.3.1. Analisis kebutuhan model

Berdasarkan tinjauan pustaka, 1D-CNN sangat sesuai untuk data deret waktu seperti sinyal ECG karena kemampuannya dalam mengekstraksi fitur spasial dan temporal secara otomatis dari data mentah (Ahmed et al., 2023). Model ini diharapkan dapat menangani variasi dalam bentuk gelombang detak jantung dan mengidentifikasi pola-pola yang membedakan detak jantung Normal dan Abnormal.

3.3.2. Perancangan arsitektur 1D-CNN

Arsitektur model akan dirancang dengan mempertimbangkan efektivitas dan efisiensi. Rancangan umum akan mencakup urutan lapisan konvolusi 1D, *pooling*, dan *dense layer* (lapisan *fully connected*). Lapisan Konvolusi 1D: Beberapa lapisan konvolusi 1D akan digunakan untuk mengekstraksi fitur hierarkis dari sinyal detak jantung. Setiap lapisan konvolusi akan memiliki jumlah *filter* tertentu (misalnya, 64, 128, 256) dan ukuran *kernel* yang bervariasi (misalnya, 3, 5, 10) untuk menangkap pola lokal dengan skala berbeda. Fungsi aktivasi ReLU (Rectified Linear Unit) akan diterapkan setelah setiap lapisan konvolusi.

1. Lapisan *Pooling*: Setelah kelompok lapisan konvolusi, lapisan *Max-Pooling 1D* akan digunakan untuk mengurangi dimensi spasial, menyorot fitur paling menonjol, dan membuat model lebih robust terhadap variasi posisi fitur (Ahmed et al., 2023).
2. Lapisan *Batch Normalization*: Lapisan ini akan disisipkan untuk menstabilkan proses pelatihan dan mempercepat konvergensi dengan

menormalisasi *input* ke setiap lapisan pada setiap *mini-batch* (Ahmed et al., 2023).

3. Lapisan *Dropout*: Untuk mencegah *overfitting*, lapisan *Dropout* akan ditambahkan pada beberapa titik dalam arsitektur, secara acak "mematikan" sebagian neuron selama pelatihan (Ahmed et al., 2023).

Lapisan *Dense (Fully Connected)*: Setelah fitur diekstraksi oleh lapisan konvolusi dan dipipihkan (*flatten*), beberapa lapisan *Dense* akan digunakan untuk melakukan klasifikasi akhir. Lapisan *output* akan menggunakan fungsi aktivasi Sigmoid untuk klasifikasi biner (Normal/Abnormal).

3.4 Pengembangan dan implementasi model

Model akan dikompilasi dengan konfigurasi berikut:

- 1 Optimizer: *adam*
- 2 Loss Function: *categorical_crossentropy* (sesuai untuk klasifikasi multi-kelas dengan label *one-hot encoded* seperti *y_categorical*)
- 3 Metrics: *accuracy*
- 4 Hyperparameter: *Learning rate* default Adam akan digunakan. *Batch size* dan jumlah *epoch* akan ditentukan (misalnya, *batch size* 64 atau 128, dan *epoch* 100-500) dan dapat disesuaikan melalui proses *tuning*.

3.5 Pelatihan dan validasi model

Model akan dilatih menggunakan *training set* dan divalidasi secara periodik pada *validation set*.

- a. Proses Pelatihan: Model akan dilatih selama sejumlah *epoch* yang ditentukan. Selama pelatihan, *loss* dan akurasi pada *training set* akan dipantau.
- b. Validasi: Kinerja model akan dievaluasi pada *validation set* setelah setiap *epoch* atau interval tertentu. Ini membantu mendeteksi *overfitting* dan membimbing proses *hyperparameter tuning*. Teknik seperti *Early Stopping* akan dipertimbangkan untuk menghentikan pelatihan jika kinerja pada *validation set* tidak lagi membaik.

3.6 Analisis hasil dan pembuktian hipotesis

Pada tahap ini, hasil evaluasi akan dianalisis secara mendalam untuk menarik kesimpulan mengenai hipotesis penelitian. Jika kinerja model (³⁵akurasi, precision, recall, F1-score, AUC-ROC) menunjukkan nilai tinggi yang sebanding atau melampaui *benchmark* yang relevan dari penelitian terdahulu, maka hipotesis akan terbukti. Analisis akan mencakup identifikasi kekuatan dan kelemahan model, serta implikasi praktis dari temuan. Hasil analisis ini akan menjadi dasar bagi pembahasan lebih lanjut di Bab 4.

**11
BAB 4****HASIL DAN PEMBAHASAN****4.1 Testing Environment**

Proses pelatihan dan evaluasi model ini dilakukan dalam lingkungan yang dikendalikan menggunakan platform Kaggle dengan akses ke dua unit GPU T4, yang memberikan kemampuan komputasi tinggi untuk memproses data besar dan mempercepat pelatihan model berbasis jaringan saraf. Lingkungan ini memungkinkan pelatihan yang lebih efisien, mengingat penggunaan Python 3.11.11 dan pustaka yang relevan seperti TensorFlow 2.18.0, Keras 3.8.0, dan scikit-learn 1.2.2. Infrastruktur ini juga dilengkapi dengan sistem operasi Ubuntu 22.04.4 LTS, yang memastikan kompatibilitas yang luas dengan pustaka dan kerangka kerja pembelajaran mesin terkini. Dengan sistem ini, kami dapat melakukan pelatihan pada dataset yang besar secara lebih cepat dan efektif, yang esensial mengingat kompleksitas sinyal ECG yang harus diproses dalam bentuk urutan waktu (time-series).

Data yang digunakan dalam penelitian ini diambil dari MIT-BIH Arrhythmia Database, yang berisi sinyal ECG dengan dua kategori utama: normal dan abnormal. Dataset ini telah melalui berbagai tahap pemrosesan, termasuk penanganan nilai hilang, penghapusan outlier dengan menggunakan teknik z-score, dan pemilahan sinyal menggunakan metode PCA untuk visualisasi dua dimensi yang lebih mudah dianalisis. Penelitian ini mengandalkan model Convolutional Neural Network (CNN) 1D untuk melakukan klasifikasi sinyal ECG dengan tujuan membedakan antara kondisi normal dan abnormal.

4.2 Hasil

Setelah melatih model, evaluasi dilakukan menggunakan berbagai metrik, di antaranya akurasi, precision, recall, F1-score, dan ROC-AUC score, untuk menilai kinerja model dalam mengklasifikasikan sinyal ECG. Berdasarkan hasil pengujian, model menunjukkan akurasi sebesar 98.73%, yang menunjukkan bahwa sebagian besar prediksi yang dilakukan oleh model sesuai dengan label yang sesungguhnya. Ini menunjukkan kemampuan model yang sangat baik dalam membedakan antara sinyal normal dan abnormal, dengan tingkat kesalahan yang sangat rendah. Metrik precision menunjukkan bahwa model mampu mengidentifikasi dengan benar sekitar 98% dari semua prediksi kelas normal dan 100% dari kelas abnormal.

Namun, meskipun precision untuk kelas abnormal adalah 100%, nilai recall untuk kelas abnormal sedikit lebih rendah, yaitu 96%. Hal ini menunjukkan bahwa meskipun model sangat baik dalam mengidentifikasi sinyal abnormal saat mengklasifikasikannya sebagai abnormal, ada sebagian kecil data yang masih terlewatkan, yang perlu diperhatikan dalam pengembangan model lebih lanjut. Metrik F1-score, yang mengukur keseimbangan antara precision dan recall, tercatat 99% untuk kelas normal dan 98% untuk kelas abnormal, menggambarkan keseimbangan yang sangat baik dalam kemampuan model untuk mengklasifikasikan kedua kelas dengan akurasi yang tinggi.

Sementara itu, nilai ROC-AUC yang mencapai 0.9754 menunjukkan bahwa model memiliki kemampuan luar biasa dalam membedakan antara dua kelas tersebut. Nilai ini menunjukkan bahwa model sangat efisien dalam mendeteksi kelas abnormal meskipun adanya noise atau fluktuasi dalam sinyal ECG, yang merupakan tantangan besar dalam aplikasi medis nyata.

Matriks kebingungan untuk model ini memberikan gambaran yang lebih rinci tentang performa model dalam hal jumlah prediksi yang benar dan salah. Matriks tersebut menunjukkan bahwa dari 628 data yang diuji, model berhasil memprediksi 450 sampel dengan benar sebagai normal (label 0) tanpa kesalahan, serta memprediksi 170 sampel dengan benar sebagai abnormal (label 1). Namun, terdapat 8 kesalahan di mana sinyal abnormal salah diklasifikasikan sebagai normal. Hal ini memperlihatkan bahwa meskipun model bekerja dengan sangat baik, masih ada beberapa sinyal abnormal yang tidak terdeteksi, yang bisa diperbaiki dengan pengoptimalan lebih lanjut.

Hasil evaluasi yang diperoleh menunjukkan bahwa model CNN 1D yang diterapkan dalam penelitian ini memiliki kinerja yang sangat baik, dengan akurasi yang sangat tinggi dalam mendeteksi kondisi normal dan abnormal pada sinyal ECG. Keberhasilan model ini sebagian besar dapat dijelaskan oleh beberapa faktor, termasuk penggunaan CNN, yang efektif dalam mengenali pola dalam data time-series seperti sinyal ECG, serta teknik pra-pemrosesan yang matang yang memastikan kualitas data yang baik sebelum model dilatih. Selain itu, penggunaan GPU T4 pada platform Kaggle sangat mempercepat proses pelatihan, yang memungkinkan eksperimen lebih mendalam dengan parameter yang lebih banyak.

Walaupun model ini menunjukkan kinerja yang luar biasa dalam hal akurasi,³ precision, recall, dan F1-score, hasilnya juga menunjukkan bahwa masih ada ruang untuk perbaikan, terutama dalam meningkatkan recall pada kelas abnormal. Dengan mengurangi kesalahan klasifikasi pada sinyal abnormal, model ini dapat dioptimalkan lebih lanjut untuk meningkatkan kemampuannya dalam mendeteksi gangguan jantung yang lebih jarang atau lebih ringan. Selain itu, evaluasi lebih lanjut dengan dataset yang lebih beragam dan beragam jenis arrhythmia dapat membantu dalam menilai kemampuan model untuk generalisasi dalam pengaturan dunia nyata.

4.3 Evaluasi User

S

4.4 Evaluasi Sistem

L

BAB 5

SIMPULAN DAN SARAN

5.1 Simpulan

Penelitian ini telah berhasil mengembangkan dan menguji model Convolutional Neural Network 1D untuk klasifikasi sinyal ECG, yang mampu mencapai akurasi 98.73%. Hasil evaluasi yang menggembirakan ini menunjukkan bahwa model ini tidak hanya efektif dalam membedakan antara sinyal normal dan abnormal, tetapi juga sangat stabil dalam kondisi yang memiliki noise atau fluktuasi, yang sering menjadi tantangan dalam aplikasi dunia nyata. Metrik lain seperti precision, recall, F1-score, dan ROC-AUC menunjukkan bahwa model ini dapat digunakan dengan kepercayaan tinggi untuk aplikasi deteksi dini penyakit jantung, terutama dalam sistem pemantauan berbasis perangkat wearable.

Secara keseluruhan, model ini menunjukkan potensi besar dalam aplikasi medis, khususnya dalam memberikan solusi deteksi dini untuk masalah jantung. Namun, meskipun hasilnya sudah sangat baik, penelitian ini juga menemukan bahwa masih ada beberapa area untuk perbaikan lebih lanjut, terutama dalam hal pengurangan kesalahan prediksi pada kelas abnormal.

5.2 Saran

S Meskipun model ini telah menunjukkan hasil yang sangat positif, ada beberapa aspek yang dapat diperbaiki untuk memperluas aplikabilitas dan meningkatkan akurasi lebih lanjut. Salah satu area utama yang perlu ditangani adalah peningkatan recall pada kelas abnormal. Penggunaan teknik augmentasi data lebih lanjut atau peningkatan jumlah data pada kelas abnormal dapat membantu dalam mengurangi kesalahan klasifikasi pada sinyal abnormal.

Selain itu, pengembangan model untuk mengklasifikasikan jenis arrhythmia yang lebih spesifik daripada hanya dua kategori (normal dan abnormal) bisa menjadi langkah selanjutnya yang signifikan dalam memperluas kemampuan diagnosis model. Penelitian ini juga dapat diperluas dengan menerapkan model ini dalam sistem pemantauan jantung berbasis perangkat wearable, yang memungkinkan deteksi penyakit jantung secara real-time. Dengan meningkatkan kecepatan dan efisiensi

model, serta meminimalkan penggunaan sumber daya, model ini dapat dioptimalkan lebih lanjut untuk diterapkan pada perangkat dengan kemampuan komputasi terbatas.

Secara keseluruhan, dengan beberapa pengembangan lebih lanjut, model ini memiliki potensi besar untuk diterapkan dalam dunia medis, khususnya dalam meningkatkan kemampuan diagnosis otomatis dan monitoring kesehatan berbasis teknologi AI.

REFERENSI

- ³⁸ Acharya, U. R., Fujita, H., Lih, O. H., Adam, M., Tan, J. H., & Chua, C. K. (2017). ⁸³ *Automated Arrhythmia detection using spectrogram and deep convolutional neural network with long duration ECG signals*. *Information Sciences*, 405, 112–127.
- ²⁰ Acharya, U. R., Joseph, K. P., Kannathal, N., Lim, C. M., & Suri, J. S. (2006). *Heart rate variability: A review*. *Medical & Biological Engineering & Computing*, 44(12), 1031–1051.
- ²⁵ Acharya, U. R., Oh, S. L., Hagiwara, Y., Tan, J. H., & Adam, M. (2017). *A deep convolutional neural network model to classify heartbeats*. *Computers in Biology and Medicine*, 89, 389–396.
- ¹⁷ Ahmed, M. S., Khan, A. S., & Ali, N. (2023). *ECG signal classification using deep learning techniques: A systematic review*. *Computers in Biology and Medicine*, 161, 107380.
- ⁴ Ahmed, M. S., Khan, A. S., & Ali, N. (2025). *Detection of normal and abnormal ECG signals using a 1D convolutional neural network on a modified MIT-BIH dataset* (Unpublished master's thesis). Universitas Bina Nusantara, Bandung.
- ⁴⁵ American Heart Association. (2021). *What is Arrhythmia?* Retrieved from <https://www.heart.org/en/health-topics/Arrhythmia/about-Arrhythmia>
- ⁸ Bayat, O., Aljawarneh, S., Carlak, H. F., International Association of Researchers, Institute of Electrical and Electronics Engineers, & Akdeniz Üniversitesi. (2017). *Understanding of a convolutional neural network*. In *IEEE International Conference on Engineering & Technology (ICET)* (pp. 21–23). Antalya.
- ⁸⁶ Chen, Y. (2015). *Convolutional neural network for sentence classification*. Ontario.
- ²⁴ Chicco, D., & Jurman, G. (2020). *The advantages of the Matthews correlation coefficient over F1 score and accuracy in binary classification evaluation*. *BMC Genomics*, 21(1), 6.
- ⁶⁰ Clifford, G. D., Azuaje, F., & McSharry, P. (2006). *Advanced methods and tools for ECG data analysis*. Artech House.
- ⁵ Faust, O., Hagiwara, Y., Hong, T. J., Lih, O. S., & Acharya, U. R. (2018). *Deep learning for healthcare applications based on physiological signals: A review*. *Computer Methods and Programs in Biomedicine*, 161, 1–13.
- Goldberger, A. L., Amaral, L. A. N., Glass, L., Hausdorff, J. M., Ivanov, P. C., Mark, R. G., ... & Stanley, H. E. (2000). *PhysioBank, PhysioToolkit, and PhysioNet*. *Circulation*, 101(23), e215–e220.

- Guerra, I., Castro, J. M., Silva, R. A., & Fonseca, J. M. (2025). Deep learning for ECG signal analysis: A systematic review. *Biomedical Signal Processing and Control*, 97, 106367.
- Hannun, A. Y., Rajpurkar, P., Haghpanahi, M., Tison, G. H., Bourn, C., Turakhia, M. P., & Ng, A. Y. (2019). Cardiologist-level Arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network. *Nature Medicine*, 25(1), 65–69.
- Hinton, G. E., & Salakhutdinov, R. R. (2006). Reducing the dimensionality of data with neural networks. *Science*, 313(5786), 504–507.
- Kwon, S., Hong, J., & Park, Y. (2018). Smart wearable systems for personalized health monitoring. *IEEE Reviews in Biomedical Engineering*, 11, 356–367.
- Luz, E. J. d. S., Schwartz, W. R., Cámar-Chávez, G., & Menotti, D. (2016). ECG-based heartbeat classification for Arrhythmia detection: A survey. *Computer Methods and Programs in Biomedicine*, 127, 144–164.
- Martis, R. J., Acharya, U. R., Adeli, H., & Prasad, H. (2014). Application of higher order statistics for atrial Arrhythmia classification. *Biomedical Signal Processing and Control*, 8(6), 888–900.
- Moody, G. B., & Mark, R. G. (2001). The impact of the MIT-BIH Arrhythmia Database. *IEEE Engineering in Medicine and Biology Magazine*, 20(3), 45–50.
- Nab, A. (2023). *ECG Arrhythmia classification using deep learning* (Unpublished master's thesis). University of Twente.
- Nehru Institute of Technology, P. J., & R. K. (2025). Early detection of cardiac Arrhythmia using deep learning. *Journal of Medical Engineering & Technology*, 49(2), 118–124.
- Panwar, M., Singh, S., & Singh, R. (2025). Real-time ECG Arrhythmia detection using deep learning. *Biomedical Signal Processing and Control*, 95, 106300.
- Pantelopoulos, A., & Bourbakis, N. G. (2010). A survey on wearable sensor-based systems for health monitoring and prognosis. *IEEE Transactions on Systems, Man, and Cybernetics*, 40(1), 1–12.
- Rajpurkar, P., Hannun, A. Y., Haghpanahi, M., Bourn, C., & Ng, A. Y. (2017). Cardiologist-level Arrhythmia detection with convolutional neural networks. *Nature Medicine*, 25(1), 65–69.
- Sannino, G., & De Pietro, G. (2021). Deep learning for ECG signal classification: A review. *Artificial Intelligence in Medicine*, 118, 102142.
- Shaffer, F., & Ginsberg, J. P. (2017). An overview of heart rate variability metrics and norms. *Frontiers in Public Health*, 5, 258. <https://doi.org/10.3389/fpubh.2017.00258>

- Shi, H., Zhang, C., He, J., & Wang, Z. (2019). Automatic detection of Arrhythmia based on multi-scale CNN and attention-based RNN. *Journal of Biomedical Informatics*, 100, 103395.
- Taejoong Yoon. (2023). ⁶⁶*MIT-BIH Arrhythmia Dataset*. Kaggle. <https://www.kaggle.com/datasets/taejoongyoon/mitbit-arrhythmia-database>
- Xiong, Z., Stiles, M. K., & Zhao, J. (2021). A deep learning framework for automatic diagnosis of Arrhythmias using a single-lead ECG. *Journal of Electrocardiology*, 66, 29–35.
- Yildirim, O., Baloglu, U. B., Tan, R. S., & Acharya, U. R. (2018). Arrhythmia detection using deep convolutional neural network with long duration ECG signals. *Computers in Biology and Medicine*, 102, 411–420.
- Zhao, Z., Zhang, Y., Deng, Y., & Zhou, X. (2019). ECG signal denoising and classification using deep feature learning. *Medical & Biological Engineering & Computing*, 57, 1987–1998.
- Zheng, J., Zhang, Y., Wang, L., Chen, H., & Wu, X. (2020). ⁷⁷A deep learning framework for ECG-based heartbeat classification using spatial pyramid pooling. *Neural Networks*, 122, 160–169.
- Zipes, D. P., & Jalife, J. (2013). *Cardiac electrophysiology: From cell to bedside* (6th ed.). Elsevier.
- Jain, A. K. (2010). Data clustering: 50 years beyond K-means. *Pattern Recognition Letters*, 31(8), 651–666.
- Lloyd, S. (1982). Least squares quantization in PCM. *IEEE Transactions on Information Theory*, 28(2), 129–137.
- Xu, R., & Wunsch, D. (2005). Survey of clustering algorithms. *IEEE Transactions on Neural Networks*, 16(3), 645–678.
- Alinsaif, S. (2024). ³⁴Unraveling arrhythmias with graph-based analysis: A survey of the ¹⁶MIT-BIH database. *Computation*, 12(2), 21. <https://doi.org/10.3390/computation12020021>
- Eleyan, A., & Alboghbaish, E. (2024). ²Electrocardiogram signals classification using deep-learning-based incorporated convolutional neural network and long short-term memory framework. *IEEE Access*, 12, 14223–14232. <https://doi.org/10.1109/ACCESS.2024.3334562>
- Goldberger, A. L., Amaral, L. A. N., Glass, L., Hausdorff, J. M., Ivanov, P. C., Mark, R. G., Mietus, J. E., Moody, G. B., Peng, C. K., & Stanley, H. E. (2000). *PhysioBank, PhysioToolkit, and PhysioNet: Components of a new research resource for complex physiologic signals*. *Circulation*, 101(23), e215–e220. <https://doi.org/10.1161/01.CIR.101.23.e215>



PRIMARY SOURCES

1	Submitted to Binus University International Student Paper	1 %
2	ouci.dntb.gov.ua Internet Source	1 %
3	kc.umn.ac.id Internet Source	1 %
4	arxiv.org Internet Source	1 %
5	Submitted to University of Edinburgh Student Paper	1 %
6	Submitted to University of the Sunshine Coast Student Paper	1 %
7	repository.pelitabangsa.ac.id:8080 Internet Source	1 %
8	repository.unhas.ac.id Internet Source	<1 %
9	Submitted to Universitas Pertamina Student Paper	<1 %
10	www.webology.org Internet Source	<1 %
11	socs.binus.ac.id Internet Source	<1 %
12	Submitted to STT PLN Student Paper	<1 %
13	www.coursehero.com	

<1 %

-
- 14 Submitted to University of Sydney <1 %
Student Paper

-
- 15 docplayer.info <1 %
Internet Source

-
- 16 www.mdpi.com <1 %
Internet Source

-
- 17 Pushpa Choudhary, Sambit Satpathy, Arvind Dagur, Dhirendra Kumar Shukla. "Recent Trends in Intelligent Computing and Communication", CRC Press, 2025 <1 %
Publication

-
- 18 ikee.lib.auth.gr <1 %
Internet Source

-
- 19 recyt.fecyt.es <1 %
Internet Source

-
- 20 www.springerprofessional.de <1 %
Internet Source

-
- 21 www.scribd.com <1 %
Internet Source

-
- 22 Submitted to Fakultas Ekonomi Universitas Indonesia <1 %
Student Paper

-
- 23 www.slideshare.net <1 %
Internet Source

-
- 24 Submitted to Harrisburg University of Science and Technology <1 %
Student Paper

-
- 25 Submitted to University of Greenwich <1 %
Student Paper

26	Submitted to Christian University of Maranatha	<1 %
27	eprints.kwikkiangie.ac.id Internet Source	<1 %
28	naukaip.ru Internet Source	<1 %
29	www.scpe.org Internet Source	<1 %
30	id.scribd.com Internet Source	<1 %
31	repository.usni.ac.id Internet Source	<1 %
32	jurnal.polindra.ac.id Internet Source	<1 %
33	repository.ibs.ac.id Internet Source	<1 %
34	Submitted to Siksha 'O' Anusandhan University Student Paper	<1 %
35	ejournal.uksw.edu Internet Source	<1 %
36	library.binus.ac.id Internet Source	<1 %
37	repository.unair.ac.id Internet Source	<1 %
38	www.jsr.org Internet Source	<1 %
39	repositori.buddhidharma.ac.id Internet Source	<1 %

40	Internet Source	<1 %
41	Submitted to Sriwijaya University Student Paper	<1 %
42	Submitted to Syiah Kuala University Student Paper	<1 %
43	Submitted to Universitas Brawijaya Student Paper	<1 %
44	Wulan Y.C., Yasmi Y., Purba C., Wollenberg E.. "Analisa konflik: sektor kehutanan di Indonesia 1997-2003", Center for International Forestry Research (CIFOR), 2004 Publication	<1 %
45	ai-care.id Internet Source	<1 %
46	digilib.stiestekom.ac.id Internet Source	<1 %
47	repository.unpar.ac.id Internet Source	<1 %
48	Farid Andika, Sry Yunarti, Suardi Hi Baharuddin. "Klasifikasi Jenis Peralatan Gym Menggunakan Convolutional Neural Network", The Indonesian Journal of Computer Science, 2025 Publication	<1 %
49	Submitted to Universitas Putera Batam Student Paper	<1 %
50	ijisrt.com Internet Source	<1 %
51	ocs.machung.ac.id Internet Source	<1 %
52	www.frontiersin.org Internet Source	<1 %

		<1 %
53	eprints.unimudasorong.ac.id Internet Source	<1 %
54	repository.nusamandiri.ac.id Internet Source	<1 %
55	Imran Imran, Indra Yudha Koswara. "The Problematics of Determining Investigators for the Corruption Eradication Commission", SIGn Jurnal Hukum, 2023 Publication	<1 %
56	Submitted to PUCMM Virtual Student Paper	<1 %
57	Sepp Hochreiter, Jürgen Schmidhuber. "Long Short-Term Memory", Neural Computation, 1997 Publication	<1 %
58	Shankar Babu, Mahesh Babu Kota. "Synergies in Smart and Virtual Systems using computational intelligence", CRC Press, 2025 Publication	<1 %
59	Shenda Hong, Yuxi Zhou, Junyuan Shang, Cao Xiao, Jimeng Sun. "Opportunities and challenges of deep learning methods for electrocardiogram data: A systematic review", Computers in Biology and Medicine, 2020 Publication	<1 %
60	Submitted to Universidad de Burgos UBUCEV Student Paper	<1 %
61	Submitted to Universitas Esa Unggul Student Paper	<1 %
62	Submitted to iGroup Student Paper	<1 %

63	Submitted to Bogazici University Student Paper	<1 %
64	Submitted to Institut Bisnis dan Teknologi Indonesia (INSTIKI) Student Paper	<1 %
65	Submitted to Universitas Indonesia Student Paper	<1 %
66	bmccardiovascdisord.biomedcentral.com Internet Source	<1 %
67	dspace.uii.ac.id Internet Source	<1 %
68	johannessimatupang.wordpress.com Internet Source	<1 %
69	jurnalku.org Internet Source	<1 %
70	adoc.pub Internet Source	<1 %
71	journal.almuslim.ac.id Internet Source	<1 %
72	peerj.com Internet Source	<1 %
73	www.jneonatalsurg.com Internet Source	<1 %
74	www.researchgate.net Internet Source	<1 %
75	Angga Ardiansyah, Candra Agustina, Ina Maryani, Denny Pribadi. "Analisis Sentimen pada Komentar YouTube terkait Pembahasan eSIM Menggunakan Metode Naive Bayes dan Random Forest", Indonesian Journal on Software Engineering (IJSE), 2025 Publication	<1 %

- 76 B. S. Raghavendra, Deep Bera, Ajit S. Bopardikar, Rangavittal Narayanan. "Cardiac arrhythmia detection using dynamic time warping of ECG beats in e-healthcare systems", 2011 IEEE International Symposium on a World of Wireless, Mobile and Multimedia Networks, 2011 <1 %
Publication
-
- 77 Jia Li, Yujian Si, Liuqi Lang, Lixun Liu, Tao Xu. "A Spatial Pyramid Pooling-Based Deep Convolutional Neural Network for the Classification of Electrocardiogram Beats", Applied Sciences, 2018 <1 %
Publication
-
- 78 core.ac.uk <1 %
Internet Source
-
- 79 ojs.trigunadharma.ac.id <1 %
Internet Source
-
- 80 patents.google.com <1 %
Internet Source
-
- 81 repository.wima.ac.id <1 %
Internet Source
-
- 82 www.grafati.com <1 %
Internet Source
-
- 83 backend.orbit.dtu.dk <1 %
Internet Source
-
- 84 es.scribd.com <1 %
Internet Source
-
- 85 idoc.pub <1 %
Internet Source
-
- 86 www.biorxiv.org <1 %
Internet Source

87	www.mbastudies.co.id Internet Source	<1 %
88	zone.biblio.laurentian.ca Internet Source	<1 %
89	Hanna Willa Dhany, Aminuddin Indra Permana, Fahmi Izhari, Andhika Pratama Ginting, Zahari Gilang Pratama. "Aplikasi Prediksi Serangan Jantung Untuk Warga Kelurahan Pelawi Utara", Jurnal Minfo Polgan, 2024 Publication	<1 %
90	Hendra Sutrisno, Nurul Anisa Sri Winarsih. "Klasifikasi Kategori Produk untuk Manajemen Keuangan Remaja menggunakan Algoritma Long Short-Term Memory", Edumatic: Jurnal Pendidikan Informatika, 2024 Publication	<1 %
91	Submitted to Universidad Pontificia Bolivariana Student Paper	<1 %
92	acikerisim.karabuk.edu.tr:8080 Internet Source	<1 %
93	ark1st.tistory.com Internet Source	<1 %
94	docobook.com Internet Source	<1 %
95	journal.aisyahuniversity.ac.id Internet Source	<1 %
96	jpti.journals.id Internet Source	<1 %
97	jtiik.ub.ac.id Internet Source	<1 %

98	lib.unnes.ac.id Internet Source	<1 %
99	repo.uinsatu.ac.id Internet Source	<1 %
100	repository.unsri.ac.id Internet Source	<1 %
101	studentsrepo.um.edu.my Internet Source	<1 %
102	turkiyeklinikleri.com Internet Source	<1 %
103	www.asau.ru Internet Source	<1 %
104	www.ihsa.ca Internet Source	<1 %
105	www.jer.or.id Internet Source	<1 %
106	www.kompas.com Internet Source	<1 %
107	Σωτήρχος, Στυλιανός. "Αξιοποίηση Δεδομένων του Πραγματικού Κόσμου με Εφαρμογή Τεχνικών Μηχανικής Μάθησης", University of Piraeus (Greece), 2024 Publication	<1 %
108	Geoffrey E. Hinton, Simon Osindero, Yee-Whye Teh. "A Fast Learning Algorithm for Deep Belief Nets", Neural Computation, 2006 Publication	<1 %
109	Jonah Kenei, Juliet Moso. "Classification of Heartbeats Using Convolutional Neural Network with Range Normalization", Medinformatics, 2025 Publication	<1 %

110

Sebastian Ubaidillah Royan, Nana Suarna,
Irfan Ali, Dodi Solihudin. "ANALISIS SENTIMEN
ULASAN PRODUK SKINCARE DI SHOPEE
UNTUK MENINGKATKAN KUALITAS PRODUK
MENGGUNAKAN METODE SUPPORT VECTOR
MACHINE", Jurnal Informasi dan Komputer,
2025

<1 %

Publication

Exclude quotes Off

Exclude matches Off

Exclude bibliography Off
