


BAB 2

TINJAUAN REFERENSI

2.1 Elektrokardiogram

Elektrokardiogram (ECG) adalah sinyal biologis yang merekam aktivitas listrik dari jantung melalui elektroda di kulit (Ashley & Niebauer, 2004). Sinyal ECG terdiri dari 3 gelombang utama, seperti yang ditunjukkan pada **Gambar 2.1**, yaitu gelombang P, yang merepresentasikan depolarisasi atrium, gelombang QRS, yang merepresentasikan depolarisasi ventrikel, dan gelombang T, yang merepresentasikan repolarisasi ventrikel. Sinyal ECG ini memiliki rentang frekuensi sekitar 0,05 Hz - 1000 Hz dan rentang listrik sekitar 1 mV - 10 mV secara normal (Velayudhan & Peter, 2016).




Gambar 2.1 Sinyal Elektrokardiogram

Mungkin terdapat sinyal yang tidak diinginkan atau suara bising yang dapat digabungkan dengan sinyal ECG yang sebenarnya selama perekaman. Derau ini harus dihilangkan, jika tidak, maka akan menyebabkan masalah analisis yang dapat menyebabkan diagnosis yang salah. Derau itu sendiri memiliki karakteristik frekuensi, sehingga dengan menghilangkan atau melewati rentang frekuensi tertentu akan menghasilkan sinyal ECG yang sebenarnya.

2.2 Denoising dalam pemrosesan sinyal ECG

Dalam pengolahan sinyal biomedis, khususnya sinyal Electrocardiogram (ECG), keberadaan dari noises merupakan salah satu tantangan utama yang dapat mempengaruhi akurasi dari analisis. Noise ini dapat berasal dari berbagai sumber seperti baseline wander, powerline interference, Gerakan pasien maupun aktivitas dari otot. Oleh karena itu, tahapan denoising ini menjadi Langkah esensial pada pra-

pemrosesan sinyal ECG sebelum dilakukan pelatihan model CNN. Dalam Konteks penelitian ini, proses denoising tidak dilakukan melalui metode eksplisit namun dilakukan melalui pendekatan yang structural dan segmentatif. Data ECG yang digunakan bersumber dari MIT-BIH Arrhythmia Database yang telah dianotas oleh ahli dan hanya mencakup sinyal yang relevan dengan peristiwa detak jantung. Proses seperti trimming Panjang sinyal normal, pemindahan label ke posisi akhir dan shifting secara tidak langsung berkontribusi dalam menghilangkan bagian sinyal yang mengandung noise, seperti area sebelum dan sesudah terdeteksi seperti pada **Gambar 2.2**




Gambar 2.2 Denoising ECG

Strategi ini termasuk dalam pendekatan *implicit noise reduction*, yaitu penghapusan *noise* melalui seleksi segmen dan normalisasi struktur data alih-alih melalui filter matematis. Hal ini terbukti efektif karena model deep learning, khususnya *hybrid CNN-LSTM*, sangat sensitif terhadap variasi struktural maupun numerik pada input data (Faust et al., 2018). Dengan demikian, meskipun tidak menggunakan teknik denoising eksplisit, penelitian ini telah menerapkan prinsip denoising secara adaptif melalui strategi segmentasi dan pemangkasan berbasis anotasi yang memperkuat robustness model terhadap variasi sinyal yang berasal dari noise.

2.3 Deteksi *Arrhythmia*, Sinyal Abnormal dan Variabilitas Sinyal

Arrhythmia adalah kondisi abnormal dari ritme jantung yang dapat mengancam jiwa, seperti takikardia ventrikular (VT) pada **Gambar 2.3**, fibrilasi ventrikular (VF) pada **Gambar 2.4**, dan fibrilasi atrium (AF) pada **Gambar 2.5**. Kondisi ini menyebabkan denyut jantung menjadi terlalu cepat, terlalu lambat, atau tidak teratur. *Arrhythmia* terjadi ketika impuls listrik yang mengatur detak jantung tidak bekerja


dengan baik, sehingga menyebabkan aktivitas elektrik jantung menjadi kacau (Zipes & Jalife, 2013). Menurut *American Heart Association* (AHA), *arrhythmia* merupakan penyebab utama dari berbagai komplikasi kardiovaskular, dan deteksi dini melalui ECG menjadi komponen penting dalam pencegahan gagal jantung dan stroke (AHA, 2021).



Gambar 2.3 Takikardia Ventrikel (VT)



Gambar 2.4 fibrilasi ventrikular (VF)



Gambar 2.5 fibrilasi atrium (AF)

Dalam konteks klasifikasi sinyal ECG, seluruh bentuk detak jantung abnormal dikategorikan sebagai kelas "1" atau *arrhythmia*, sedangkan detak jantung normal diklasifikasikan sebagai "0". Klasifikasi biner ini disesuaikan dengan pendekatan machine learning yang digunakan dalam penelitian ini agar lebih efisien dalam

pemodelan dan analisis. Pengkategorian seluruh jenis kelainan detak jantung ke dalam satu label umum (*arrhythmia*) dianggap cukup representatif pada tahap awal klasifikasi, terutama saat model difokuskan pada deteksi keberadaan kelainan, bukan spesifikasinya (Faust et al., 2018). Dalam konteks klasifikasi sinyal ECG, seluruh bentuk detak jantung abnormal dikategorikan sebagai kelas "1" atau *arrhythmia*, sedangkan detak jantung normal diklasifikasikan sebagai "0". Klasifikasi biner ini disesuaikan dengan pendekatan machine learning yang digunakan dalam penelitian ini agar lebih efisien dalam pemodelan dan analisis. Pengkategorian seluruh jenis kelainan detak jantung ke dalam satu label umum (*arrhythmia*) dianggap cukup representatif pada tahap awal klasifikasi, terutama saat model difokuskan pada deteksi keberadaan kelainan, bukan spesifikasinya (Faust et al., 2018).

2.4 Heart Rate Variability

Heart Rate Variability (HRV) adalah ukuran fluktuasi waktu antara dua detak jantung berturut-turut, yang biasanya dihitung dari interval RR pada sinyal ECG. HRV mencerminkan keseimbangan antara sistem saraf simpatis dan parasimpatis, dan sering digunakan sebagai indikator kesehatan kardiovaskular serta stres fisiologis (Shaffer & Ginsberg, 2017). Secara umum, HRV dapat dianalisis melalui tiga pendekatan utama: domain waktu (misalnya SDNN, RMSSD), domain frekuensi (misalnya LF, HF, LF/HF ratio), dan domain non-linear (misalnya *Poincaré plot*, *entropy*). Dalam penelitian berbasis *machine learning*, fitur-fitur HRV ini sering digunakan untuk membedakan kondisi detak jantung normal dan abnormal (Acharya et al., 2006). Fitur HRV yang rendah biasanya menunjukkan kondisi abnormal seperti *arrhythmia* atau stres jantung, sementara nilai HRV yang tinggi menandakan sistem otonom yang sehat dan adaptif. Dalam konteks penelitian ini, HRV memiliki relevansi sebagai sinyal pembeda yang dapat digunakan sebagai input untuk model CNN atau LSTM, atau sebagai penanda penurunan kualitas ritme jantung.

2.5 Dataset MIT-BH *Arrhythmia*

MIT-BIH *Arrhythmia* Database merupakan salah satu dataset benchmark paling komprehensif dan banyak digunakan dalam penelitian analisis sinyal elektrokardiogram (ECG). Dataset ini dikembangkan oleh Beth Israel Hospital bekerja sama dengan Massachusetts Institute of Technology (MIT) dan tersedia secara publik melalui platform PhysioNet dan Kaggle (Goldberger et al., 2000; Yoon, 2023). Dataset ini terdiri dari 48 rekaman ECG dua channel berdurasi sekitar 30 menit, yang direkam

dari 47 pasien rawat jalan dan rumah sakit. Setiap rekaman memiliki dua lead: MLII (Modified Lead II) dan V1, serta disampling pada frekuensi 360 Hz. Rekaman ini telah dianotasi secara manual oleh ahli jantung, mencakup lebih dari 100.000 detak jantung yang diklasifikasikan ke dalam lebih dari 15 tipe detak, seperti detak normal (N), *premature ventricular contraction* (V), *atrial premature beat* (A), dan lainnya.

Struktur data terdiri dari:

1. *Signal Time Series*: data numerik sinyal ECG dalam satuan milivolt.
2. *Sample Index*: titik waktu untuk setiap anotasi detak.
3. *Annotation Label*: label untuk tiap detak, sesuai klasifikasi AAMI (Association for the Advancement of Medical Instrumentation).

Dalam penelitian ini, dataset digunakan dalam format yang telah disederhanakan dan diproses ulang oleh Taejoong Yoon melalui Kaggle, yang menggabungkan sinyal berdurasi pendek (segmentasi) dan mengelompokkan tipe detak jantung menjadi dua kelas utama, yaitu:

1. Label 0: Detak jantung normal
2. Label 1: Detak jantung abnormal (*arrhythmia*)

Penggunaan dataset ini sangat sesuai untuk pengembangan dan evaluasi sistem diagnosis otomatis berbasis machine learning karena:

1. Anotasi dilakukan secara manual oleh ahli jantung
2. Sinyal tersedia dalam format digital dan dapat diakses
3. Mencakup variasi besar dalam kondisi fisiologis dan patologis

Dataset ini juga dilengkapi dengan metadata tambahan seperti jenis kelamin pasien, lead yang digunakan, dan waktu perekaman. Dengan demikian, MIT-BIH *Arrhythmia* Database tidak hanya memberikan sinyal ECG mentah, tetapi juga konteks klinis yang dapat membantu dalam interpretasi hasil klasifikasi dan generalisasi model terhadap populasi yang lebih luas. Dataset versi Kaggle oleh Taejoong Yoon (2023) menyediakan data ini dalam format yang lebih mudah diakses, dengan pembagian detak jantung menjadi normal dan abnormal berdasarkan tipe anotasi. Dataset ini sangat berguna untuk melatih dan mengevaluasi model machine learning karena mengandung variasi besar dalam kondisi kardiak.

2.6 Modifikasi Data

Setelah data terkumpul, dilakukan proses modifikasi guna membentuk struktur data yang siap digunakan untuk pelatihan model machine learning. Salah satu tahapan utama adalah pembentukan sub-dataset dengan mengambil sampel rekaman secara acak dari database besar untuk menjaga keberagaman representasi sinyal. Kemudian, dilakukan proses segmentasi sinyal menjadi *fixed-length windows* yang merepresentasikan satu siklus detak jantung. Proses ini merujuk pada studi Murali et al. (2025), yang menyarankan pemotongan sinyal ECG berdasarkan jarak antar *R-peak* atau menggunakan pendekatan *sliding window* dengan jumlah sampel konstan seperti 200 titik. Tujuan dari segmentasi ini adalah untuk menciptakan representasi spasial-temporal yang konsisten untuk setiap *heartbeat cycle*, mengingat variasi panjang sinyal dapat mengganggu pelatihan model konvolusional.

Tahap selanjutnya adalah *reclassification* label dari bentuk multikategori menjadi dua kelas biner yaitu Normal dan Abnormal. Panwar et al. (2025) menyebutkan bahwa pendekatan klasifikasi biner tidak hanya menyederhanakan kompleksitas model, tetapi juga lebih efisien pada aplikasi real-time dan perangkat portabel. Semua kategori *arrhythmia* seperti *Premature Ventricular Contraction* (PVC), *Atrial Fibrillation* (AF), dan *Ventricular Tachycardia* (VT) diklasifikasikan ke dalam kelas Abnormal. Hal ini juga bertujuan mempermudah penilaian performa awal model sebelum dilakukan klasifikasi lanjutan secara multi-kelas. Sebagai langkah validasi kemampuan generalisasi model, sebagian kecil data yang belum dibersihkan secara ekstensif juga disisihkan sebagai *prediction dataset*, yang akan digunakan untuk menguji performa model terhadap data *noisy* yang lebih menyerupai kondisi di lapangan.

2.7 Persiapan data

Persiapan data dimulai dengan eksplorasi data menggunakan metode *exploratory data analysis* (EDA) untuk memahami distribusi data, mendeteksi nilai kosong, dan mengidentifikasi outlier. (Zahid et al., 2020) menunjukkan bahwa *outlier* pada data ECG dapat berdampak besar terhadap performa model deteksi, terutama dalam hal sinyal ekstrem akibat gangguan perangkat keras atau noise. Oleh karena itu, dilakukan pembersihan dengan teknik *Z-score normalization*. Nilai *Z-score* dihitung dengan mengukur seberapa jauh jarak titik data dari rata-rata populasi dalam standar deviasi. Data dengan nilai *Z-score* > 3 dikategorikan sebagai outlier dan dibuang dari dataset.

untuk mencegah distorsi. Setelah data dibersihkan, tahapan dilanjutkan dengan standarisasi dan pembentukan *Context Window*.

2.7.1 Standard Scaler

Mengingat model machine learning sangat sensitif dengan variasi rentang nilai input, dilakukan normalisasi amplitudo untuk menyeragamkan skala data memakai teknik *Standard Scaler*. Sedangkan untuk menghitung *Standard Scaler* itu sendiri menggunakan **persamaan (1)**:

$$z = \frac{x - \mu_{\text{train}}}{\sigma_{\text{train}}} \quad (1)$$

di mana x merupakan nilai amplitudo sinyal, μ adalah rata-rata dari data latih, dan σ adalah standar deviasi dari data latih. Langkah ini menerapkan prinsip *No-Peeking* yang ketat untuk mencegah terjadinya kebocoran data. Paramter statistik hanya dihitung berdasarkan data latih. Nilai tersebut kemudian disimpan dan digunakan untuk mentransformasi data validasi dan data uji. Hal ini dilakukan untuk memastikan bahwa model tersebut tidak mengintip karakteristik dari data uji dan mensimulasikan kondisi nyata dimana data pasien baru bersifat tidak diketahui.

2.7.2 Context Windows

Salah satu tantangan dari mendeteksi aritmia adalah ketergantungan diagnosis pada pola ritme antar detak jantung, bukan hanya morfologi satu detak tunggal. Beberapa jenis aritmia mempunyai pola spesifik yang bersifat ritmis yaitu:

- b. Bigeminy : Dimana pola ini adalah setiap satu detak jantung normal diikuti oleh satu detak prematur secara bergantian (Pola : Normal – Abnormal – Normal – Abnormal).
- c. Trigeminy : Dimana pola ini adalah dua detak normal diikuti oleh satu detak prematur (Pola : Normal – Normal – Abnormal).


Jika model hanya melihat satu detak secara terisolasi, pola ritmis ini tidak akan terdeteksi. Oleh karena itu, secara teoritis dibutuhkan pendekatan *Context Windows* dengan lebar 7 detak jantung yang terdiri dari 3 detak jantung sebelumnya, 1 detak jantung pusat dan 3 detak jantung setelahnya. Pendekatan ini memungkinkan model CNN yang dipakai untuk mengekstraksi fitur temporal jangka panjang dan bisa mengenali transisi ritme jantung yang abnormal secara lebih akurat.

2.8 CNN dan Conv-1D

Convolutional Neural Network (CNN) adalah salah satu jenis deep neural network yang menggunakan operasi linear matematika antar matriks yang disebut dengan *convolution* (Bayat et al., 2017). CNN dirancang untuk mendeteksi pola atau struktur spasial dari data dan telah menjadi metode utama dalam berbagai bidang seperti pengenalan pola (pattern recognition), klasifikasi sinyal, dan pengolahan citra medis. Aspek penting dari CNN adalah kemampuannya untuk melakukan reduksi parameter secara signifikan dibandingkan dengan *Artificial Neural Network* (ANN), sehingga menjadikan CNN lebih efisien dan unggul dalam mendeteksi fitur kompleks dari data masukan (Bayat et al., 2017). Arsitektur CNN terdiri dari beberapa layer konvolusi, aktivasi, pooling, dan fully connected yang saling terhubung, sehingga memungkinkan proses ekstraksi fitur secara bertingkat dari input mentah hingga representasi tingkat tinggi.

Berdasarkan dimensi input yang ditangani, CNN terbagi menjadi:

1. 1-D CNN untuk data sinyal dan deret waktu (time-series), seperti sinyal ECG, pengenalan suara (*voice recognition*), dan analisis teks.
2. 2-D CNN untuk data gambar atau peta fitur dua dimensi.
3. 3-D CNN untuk data spasio-temporal seperti video atau citra medis 3D (MRI, CT-scan).



Gambar 2.6 Arsitektur 1-D CNN

Dalam konteks penelitian ini, kami menggunakan 1-D CNN untuk menganalisis sinyal ECG satu dimensi dan contoh visualisasinya ada pada **Gambar 2.6**. Layer konvolusi satu dimensi (Conv1D) secara spesifik melakukan operasi konvolusi dengan cara menggeser kernel sepanjang dimensi waktu. Setiap kernel akan mengekstrak fitur

lokal seperti pola QRS kompleks, gelombang P dan T. Dengan parameter seperti kernel size, stride, dan padding, struktur Conv1D dapat disesuaikan dengan panjang dan resolusi sinyal input. Penggunaan Conv1D pada model CNN terbukti efektif dalam mengekstraksi fitur spasial dari sinyal ECG.

2.9 Algoritma Pan-Tompkins

Untuk mendeteksi lokasi R-Peak secara otomatis dan akurat, penelitian ini mengimplementasikan algoritma Pan-Tompkins. Algoritma ini diakui secara luas sebagai standar dalam pemrosesan sinyal biomedis karena efisiensi komputasi serta ketahanan terhadap gangguan *noise* (Elgendi et al., 2014). Berdasarkan studi oleh Pan dan Tompkins pada tahun 1982, algoritma ini bekerja melalui serangkaian filter digital dan mekanisme pengambilan keputusan yang adaptif untuk mengisolasi kompleks QRS. Pada proses ini terdiri dari lima tahapan utama yaitu:

1. *Band-Pass Filtering* Langkah ini bertujuan untuk mengurangi interferensi, termasuk dari *muscle noise* frekuensi tinggi dan *baseline* frekuensi rendah. Filter *band-pass* dibentuk melalui *Low-pass filter* dan *High-Pass filter* untuk meloloskan frekuensi pada rentang 5-15 Hz yang dimana frekuensi ini adalah spektrum energi dominan dari Komplek QRS tersebut. (Pan & Tompkins, 1985). Untuk *Low-pass filter* itu sendiri didefinisikan pada **persamaan(2)**:

$$y(nT) = 2y(nTT) - y(nT - 2T) + x(nT) - 2x(nT - 6T) + (x(nT - 12T) \quad (2)$$

Sedangkan untuk *High-pass filter* itu sendiri didefinisikan di **persamaan(3)**:

$$y(nT) = 32x(nT - 16T) - [y(nT - T) + x(nT) - x(nT - 32T)] \quad (3)$$

2. *Diferensiasi (Derivative)* setelah melakukan filtering, dilakukan operasi turunan untuk mengekstraksi *slope* sinyal. Kompleks dari QRS ini dibedakan dari gelombang ECG frekuensi rendah lainnya melalui kemiringan yang curam. Untuk *derivative* tersebut didefinisikan pada **persamaan(4)**:

$$y(nT) = \frac{1}{8T} [-x(nT - 2T) - 2x(nT - T) + 2x(nT + T) + x(nT + 2t)] \quad (4)$$

3. *Squaring Function* sinyanya dari hasil diferensiasi kemudian dikuadratkan secara *point bt point* yang ditunjukkan pada **persamaan(5)**:

$$y(nT) = [x(nT)]^2 \quad (5)$$

Tahapan ini berfungsi untuk mengubah keseluruhan nilai menjadi positif dan mempertegas karakteristik frekuensi tinggi secara non0linear, sehingga dapat meminimalkan potensi kesalahan deteksi akibat gelombang T yang tinggi.

4. *Moving Window Integration* untuk memperoleh informasi dari gelombang yang lebih halus selain dari kemiringan. Sinyal dari hasil *squaring* diintegrasikan menggunakan jendela waktu N yang pada umumnya bernilai 150ms dan ditunjukkan pada **persamaan(6)**:

$$y(nT) = \frac{1}{N} [x(nT - (N - 1)T) + x(nT - (N - 2)T) + \dots + x(nT)] \quad (6)$$

5. *Adaptive Thresholding* dan Mekanisme keputusan Tahap akhir ini melibatkan penentuan lokasi R-Peak menggunakan *threshold* yang beradaptasi secara dinamis terhadap kondisi sinyal dan noise.

1. *Refractory Period* : setelah sebuah QRS valid terdeteksi, sistem menerapkan periode refraktori pada sekitar 200ms yang dimana deteksi baru diabaikan sepenuhnya untuk mencegah *double detection*.
2. *Search-back mechanism* : Algoritma memantau rata-rata dari interval R-R. Jika tidak ada QRS yang terdeteksi pada interval waktu tertentu dari rata-rata interval R-R sebelumnya, sistem akan mengasumsikan adanya puncak yang terlewat. Ambang batas kemudian diturunkan dan dilakukan pencarian ulang untuk mencari QRS dengan amplitudo rendah.

2.10 Kinerja Model

Evaluasi kinerja merupakan elemen krusial dalam validasi model klasifikasi, khususnya dalam konteks medis seperti pendeteksian *arrhythmia* jantung dari sinyal elektrokardiogram (ECG). Model yang digunakan perlu dievaluasi secara menyeluruh agar tidak hanya akurat secara numerik, tetapi juga dapat diandalkan dalam skenario nyata, termasuk kasus dengan distribusi kelas yang tidak seimbang.

Matriks evaluasi yang digunakan untuk menilai performa kinerja model ini antara lain adalah:

1. Akurasi : Mengukur proporsi total prediksi yang benar. Meskipun umum digunakan, metrik ini kurang representatif pada dataset dengan distribusi kelas yang timpang (Luz et al., 2016).

2. Presisi : menunjukkan seberapa besar proporsi prediksi positif yang benar dari seluruh prediksi positif dan ditunjukkan dengan **persamaan (7)** :

$$Precision = \frac{TP}{TP + FP} \quad (7)$$

Dimana *True Positive (TP)* adalah jumlah data positif yang berhasil diklasifikasikan dengan benar oleh model. *False Positive (FP)* adalah jumlah data negatif yang secara keliru diklasifikasikan sebagai positif oleh model.

3. *Recall (Sensitivity)* : mengukur seberapa jauh dan seberapa baik model dalam mendeteksi kasus positif yang sebenarnya ditunjukkan dengan **persamaan(8)**:

$$Recall = \frac{TP}{TP + FN} \quad (8)$$


Dimana TP sudah dijelaskan pada poin bagian 2. Sedangkan untuk FN itu sendiri adalah *False Negative (FN)* dimana jumlah data positif yang salah itu diklasifikasikan sebagai negatif oleh model.

4. F1-Score : F1-Score ini adalah rata-rata dari harmonisasi presisi dan recall dan digunakan untuk evaluasi pada dataset yang tidak seimbang ditunjukkan dengan **persamaan(9)**:

$$F_1 = \frac{2 \times (Precision \times Recall)}{Precision + Recall} \quad (9)$$

5. *Confusion matrix*

Matriks ini menampilkan perbandingan antara prediksi dan kenyataan dalam empat komponen: true positives (TP), true negatives (TN), false positives (FP), dan false negatives (FN) ditunjukkan pada **Gambar 2.7**.



Gambar 2.7 Confusion Matrix

2.11 *Open Neural Network Exchange (ONNX)*


Dalam pengembangan model *machine learning*, seringkali terdapat kebutuhan untuk memindahkan model dari data training ke *deployment* yang memiliki

karakteristik hardware yang berbeda. *Open Neural Network Exchange* (ONNX) ini adalah format yang dirancang untuk mengatasi masalah ini dengan menyediakan representasi model yang seragam pada berbagai framework (Bai et al., 2019). Format ini memungkinkan model yang telah dilatih menggunakan *library* seperti PyTorch, TensorFlow dan Scikit-learn untuk diekspor menjadi format biner. Keuntungan utama dari penggunaan ONNX ini adalah kemampuan optimasi graf komputasi secara otomatis yang dapat mempercepat proses prediksi dan penggunaan memori yang lebih sedikit dibandingkan menjalankan model pada framework aslinya. Efisiensi ini menjadikan model ONNX adalah solusi yang tepat untuk implementasi sistem pada perangkat yang ada.

2.12 *Unified Modeling Language* (UML) dan *Use Case Diagram*

Untuk visualisasi arsitektur dan interaksi fungsional pada sistem yang dikembangkan, penelitian ini menggunakan standar *Unified Modeling Language* (UML). Menurut Pressman (2014), UML adalah bahasa pemodelan standar yang digunakan untuk mendokumentasikan, menspesifikasikan, dan membangun sistem *software* berorientasi objek. Dalam konteks perancangan *interface* pada penelitian ini, fokus pemodelan dilakukan dengan menggunakan *Use Case Diagram*.

Diagram ini digunakan untuk menggambarkan hubungan antara sistem dan lingkungan eksternalnya serta mendefinisikan apa yang dilakukan oleh sistem tanpa harus menjelaskan secara terperinci bagaimana sistem melakukannya. Diagram ini terdiri dari 4 komponen utama. Pertama, Aktor yang dilambangkan dengan gambar orang yang merepresentasikan entitas eksternal yang berinteraksi dengan sistem. Kedua, *Use Case* yang dilambangkan dengan bentuk oval yang merepresentasikan fungsional secara spesifik atau layanan yang disediakan oleh sistem. Ketiga, Asosiasi yang berupa garis penghubung yang menampilkan hubungan aktif antara aktor dan *use case*. Terakhir, batasan sistem yang dilambangkan dengan kota persegi panjang yang membungkus seluruh *use case* untuk memisahkan ruang lingkup internal sistem dari lingkungan eksternalnya. Secara umum, *Use Case Diagram* dapat divisualisasikan pada **Gambar 2.8** berikut.



Gambar 2.8 Contoh *Use Case Diagram*

2.13 Related works

Penelitian ini bukanlah yang pertama yang mencoba memprediksi *arrhythmia* jantung. Sejumlah penelitian sebelumnya telah mengeksplorasi domain ini menggunakan berbagai teknik pembelajaran mesin, mulai dari jaringan saraf dasar hingga arsitektur yang lebih canggih seperti CNN-LSTM. Beberapa karya terkait ini dirangkum dalam **Tabel 2.1**.

Tabel 2.1 Related Works

<i>Author</i>	<i>Description</i>	<i>Method</i>	<i>Dataset</i>	<i>Accuracy</i>
(Ebrahimzadeh et al., 2014)	<i>Single patient's HRV and One minute prior VF</i>	<i>Neural Network</i>	Holter	99.7%
(Ebrahimzadeh et al., 2014)	<i>Single patient's HRV and three minutes prior VF</i>	<i>Neural Network</i>	Holter	90.3%
(Ebrahimzadeh et al., 2014)	<i>Single patient's</i>	<i>Neural Network</i>	Holter	83.9%

	<i>HRV and four minutes prior VF</i>			
(Zheng et al., 2020)	<i>Classifying non-SCD</i>	<i>CNN-LSTM</i>	MIT-BIH	99%
(Warrick & Nabhan Homs, 2017)	<i>Classifying non- SCD</i>	<i>CNN-LSTM</i>	Physionet Challenge 2017	83%
(Oh et al., 2018)	<i>Classifying non- SCD</i>	<i>CNN-LSTM</i>	MIT-BIH	99%
(Shi et al., 2019)	<i>Classifying non- SCD</i>	<i>CNN- LSTM</i>	MIT-BIH	98%

Sebagai contoh, Ibte haz *et al.* (2019) melaporkan akurasi klasifikasi yang mengesankan, yaitu hampir 99% ketika membedakan antara kejadian fibrilasi ventrikel (VF) dan non-VF. Namun, model mereka secara khusus dirancang untuk mendeteksi kejadian hanya beberapa detik sebelum terjadinya kematian jantung mendadak (SCD), sehingga membatasi kesempatan untuk intervensi medis yang tepat waktu. Peneliti lain, termasuk Ebrahimzadeh *et al.* (2014), Lee *et al.* (2016), dan Joo *et al.* (2010), mengadopsi metodologi prapemrosesan dan pemilihan fitur yang serupa. Mereka terutama berfokus pada indikator *Heart Rate Variability* (HRV), khususnya interval RR, yang mewakili waktu antara puncak R yang berurutan dalam sinyal ECG. Ukuran statistik seperti rata-rata dan deviasi standar interval RR, bersama dengan variabilitas periode pernapasan, diekstraksi dan dievaluasi menggunakan nilai-p untuk menentukan signifikansi statistiknya. Hanya fitur yang paling berpengaruh yang dipilih sebagai masukan untuk masing-masing model. Perbedaan utama di antara penelitian-penelitian ini terletak pada arsitektur jaringan saraf yang digunakan. Lee *et al.* (2016) mengimplementasikan jaringan saraf tiruan dengan satu dan dua lapisan tersembunyi, masing-masing terdiri dari lima neuron. Sebaliknya, Joo *et al.* (2010) menggunakan arsitektur yang lebih dalam dengan dua lapisan tersembunyi, masing-masing berisi 25 neuron, yang menghasilkan peningkatan waktu pelatihan dan kompleksitas komputasi.

Sementara itu, Ebrahimzadeh *et al.* (2014) membandingkan kinerja Multi-Layer Perceptron (MLP) dengan pengklasifikasi K-Nearest Neighbor (KNN).

Pendekatan alternatif diusulkan oleh Farhadi *et al.* (2017), yang menggunakan Algoritma Genetika (GA) sebagai teknik optimasi. Daripada mengonfigurasi arsitektur model secara manual, GA digunakan untuk secara otomatis mengidentifikasi kombinasi fitur dan struktur jaringan yang optimal, menggunakan set data yang sama dan fitur berbasis HRV. Khususnya, metode ini memungkinkan pengecualian fitur-fitur domain frekuensi, yang sering kali sulit untuk diekstraksi dan diinterpretasikan. Lebih lanjut, Rajput *et al.* (2019) menekankan bahwa sinyal ECG mentah dapat secara efektif dimasukkan ke dalam model pembelajaran mendalam, sehingga memungkinkan model untuk mempelajari fitur-fitur yang relevan secara mandiri tanpa memerlukan rekayasa fitur secara manual. Hal ini mendukung gagasan tentang jalur pembelajaran ujung ke ujung untuk deteksi *arrhythmia*. Dalam penelitian lain, Verma dan Dong (2016) mencapai lebih dari 94% akurasi dalam membedakan ritme VF dari non-VF menggunakan fitur yang diturunkan dari HRV dan pengklasifikasi hutan acak. Berdasarkan upaya ini, penelitian saat ini bertujuan untuk memasukkan takikardia ventrikel (VT) sebagai kelas tambahan yang akan diprediksi. Secara kolektif, model CNN-LSTM telah menunjukkan efektivitas yang substansial dalam mendeteksi dan mengklasifikasikan irama jantung. Meskipun sebagian besar penelitian sebelumnya memanfaatkan arsitektur ini untuk ekstraksi fitur dan klasifikasi VT/VF, mereka umumnya tidak menyertakan komponen prediksi atau peramalan-sehingga membatasi potensi intervensi dini. Sebagai tanggapan, penelitian ini mengusulkan integrasi CNN dan LSTM untuk tidak hanya mengklasifikasikan tetapi juga meramalkan kemungkinan terjadinya VF atau VT dan memberi waktu untuk tindakan pencegahan.