


BAB 3

METODE PENELITIAN

3.1 Tahapan penelitian

Proses penelitian akan dibagi menjadi beberapa tahapan utama yang terstruktur, dimulai dari persiapan data hingga evaluasi model, seperti yang digambarkan pada **Gambar 3.1**.



Gambar 3.1 Tahapan Penelitian

Penelitian ini dirancang dengan pendekatan sistematis yang terdiri dari lima fase utama yang saling mendukung, yaitu: perolehan data, modifikasi data, persiapan data, pelatihan model, serta evaluasi hasil. Seluruh alur kerja ini bertujuan untuk membangun sistem klasifikasi *arrhythmia* jantung berbasis sinyal ECG menggunakan metode pembelajaran mendalam dengan klasifikasi dua kelas (normal vs abnormal). Pada tahap awal yaitu *Data Gathering*, focus utama adalah eksplorasi literatur dan pengumpulan bahan baku penelitian. Studi literatur dilakukan untuk menelusuri metode *state-of-the-art* dalam deteksi *arrhythmia* serta memahami karakteristik sinyal fisiologis. Berdasarkan kajian tersebut, dilakukan pengumpulan data (*Dataset Gathering*) yang bersumber dari *MIT-BIH Arrhythmia Database* melalui repositori Kaggle. Data yang diperoleh kemudian melalui proses visualisasi awal (*Dataset Visualization*) untuk memahami distribusi sinyal dan memastikan kualitas data sebelum masuk ke tahap pemrosesan lebih lanjut (Goldberger et al., 2000; Yoon, 2023).

Tahapan berikutnya berfokus pada *Data Modification*, di mana struktur data disesuaikan agar kompatibel dengan arsitektur *Deep Learning*. Berbeda dengan pendekatan konvensional, penelitian ini menerapkan teknik *New 7-beat context windows*, di mana sinyal tidak dipotong per detak tunggal, melainkan dibentuk menjadi jendela konteks yang memuat tujuh detak berurutan untuk menangkap pola temporal ritme jantung. Label anotasi kemudian disederhanakan melalui proses *Dataset binary re-labeling* menjadi dua kategori utama, yaitu Normal dan Abnormal (Panwar et al., 2025). Selanjutnya, dilakukan pembagian data menggunakan metode *Record-wise split* untuk memisahkan data pasien secara utuh antar himpunan data, guna mencegah kebocoran informasi (*data leakage*). Sebagai langkah validasi eksternal, satu rekaman data disisihkan sepenuhnya tanpa modifikasi (*reserved unmodified record*) untuk digunakan pada tahap pengujian akhir.

Memasuki fase *Modeling*, data yang telah dimodifikasi dibagi kembali secara proporsional menjadi *training*, *validation*, dan *test set* (*Train-Val-Test Split*). Tahap ini dilanjutkan dengan pendefinisian arsitektur model (*Model Definition*) menggunakan *1D-Convolutional Neural Network* (1D-CNN) yang dirancang khusus untuk mengekstraksi fitur spasial dari deret waktu ECG. Setelah arsitektur terbentuk, proses *Model Training* dijalankan dengan mengoptimalkan parameter bobot menggunakan algoritma optimasi dan fungsi kerugian yang sesuai untuk menangani ketidakseimbangan kelas, memastikan model dapat belajar membedakan pola normal dan abnormal secara efektif (Zhao et al., 2019; Hannun et al., 2019).

Fase akhir dalam metodologi ini adalah *Result*, yang mencakup evaluasi dan penerapan model. Pada tahap *Model Evaluation*, kinerja model dinilai secara komprehensif menggunakan metrik klasifikasi standar seperti akurasi, presisi, *recall*, dan AUC-ROC untuk mengukur keandalan sistem (Chicco & Jurman, 2020). Setelah model divalidasi dan menunjukkan performa yang optimal, tahap selanjutnya adalah *Model Deployment*. Pada tahap ini, model diintegrasikan ke dalam sistem antarmuka, dan rekaman data mentah yang telah disisihkan sebelumnya (*reserved unmodified record*) digunakan untuk mensimulasikan skenario pemantauan nyata, memastikan bahwa sistem mampu menangani data baru yang belum pernah dilihat sebelumnya dengan akurat.

3.2 Pemilihan dan Pemilahan Dataset

Pada tahapan ini dijelaskan bagaimana prosedur sistematis didalam pemilihan serta pemilahan dataset yang diterapkan untuk dapat mengubah data mentah dari sinyal menjadi dataset yang terstruktur yang nantinya akan digunakan sebagai model training dan model test.

3.2.1 Sumber dan Karakteristik Data Mentah

Dataset utama pada penelitian ini berasal dari MIT-BIH Arrhythmia Database yang diakses melalui repositori Kaggle. Data ini adalah data yang digunakan dalam penelitian aritmia yang terdiri dari rekaman elektrokardiogram (ECG) dalam dua saluran dari 48 pasien yang berbeda. Setiap rekaman terdiri dari dua file utama yang berpasangan:

- a. File Sinyal(.csv) File ini berisi data waktu dari amplitudo sinyal ECG yang direkam secara terus menerus dengan frekuensi sampling 360Hz. Fokus pada penelitian ini memakai saluran MLII (Modified Limb Lead II) karena memiliki gelombang QRS yang cukup jelas. Contoh dari file sinyal ini ditunjukkan pada **Tabel 3.1**.

Tabel 3.1 Contoh File Sinyal Mentah

Sampel	t_0	t_1	t_2	t_3		t_186
1	0.963	0.962	0.964	0.963		0.970
2	0.958	0.955	0.955	0.953		0.965
3	0.949	0.947	0.953	0.952		0.962
4	0.956	0.956	0.956	0.959		0.971
5	0.958	0.958	0.959	0.961		0.972

Tabel diatas menampilkan representasi dan contoh matriks dari 5 sampel pertama, kolom t_0 hingga t_186 berisi nilai amplitudo sinyal dari dataset asli. Sedangkan baris sampel menunjukkan pasien berarti ada 5 pasien yang ada pada data tersebut.

- b. File Anotasi(.txt) File ini berisi data klinis hasil diagnosis ahli kardiologi. File ini memiliki informasi berupa Sample sebagai indeks Lokasi waktu terjadinya puncak gelombang (R-peak) serta *Type* yang bertugas sebagai

label diagnosis untuk setiap detail dari detak jantung. Contoh dari file anotasi ini ditunjukkan pada **Tabel 3.2**.

Tabel 3.2 Contoh File Anotasi

Time	Sampel#	Type	Sub	Chan	Num	Aux
0:00.019	7	+	0	0	0	(N
0:00.231	83	N	0	0	0	0
0:01.100	396	N	0	0	0	0
0:01.975	711	N	0	0	0	0
0:02.867	1032	N	0	0	0	0

Pada tabel diatas tersebut struktur anotasi dari ahli. Kolom *Time* menunjukkan waktu terjadinya detak, sedangkan sampel menunjukkan Lokasi puncak gelombang R pada data dan Type menunjukkan diagnosis jenis detak tersebut.

3.2.2 Segmentasi dan Ekstraksi Sinyal


Data sinyal mentah yang bersifat kontinu tidak dapat langsung digunakan sebagai input model klasifikasi karena model membutuhkan input yang terstandarisasi. Oleh karena itu, dilakukan proses segmentasi untuk memecah sinyal panjang menjadi segmen detak jantung individual yang berpusat pada gelombang R (*R-peak*). Proses dan tahapan transformasi sinyal tersebut antara lain:

1. Deteksi R-Peak: Algoritma Pan-Tompkins digunakan untuk mendeteksi lokasi temporal dari puncak gelombang R sebagai titik referensi pusat setiap detak. Algoritma ini mencakup proses *bandpass filtering* (5-15 Hz) untuk meminimalisir *noise* otot dan *baseline wander* sebelum melakukan diferensiasi dan integrasi sinyal untuk menemukan puncak QRS yang valid.
2. Pemotongan Sinyal (*Windowing*): Berbeda dengan pendekatan simetris konvensional, penelitian ini menerapkan segmentasi asimetris dengan total panjang jendela (window size) sebesar 200 sampel (setara dengan ± 556 ms pada frekuensi 360 Hz). Pemilihan angka 200 sampel ini bertujuan untuk menangkap kompleks PQRST secara utuh. Pembagian area potong adalah sebagai berikut:

- Pre-R (90 Sampel): Mengambil 90 titik data sebelum puncak R. Durasi ini (± 250 ms) cukup untuk menangkap gelombang P dan interval PR secara lengkap, yang sering bermulai 120-200 ms sebelum puncak R.
- Post-R (110 Sampel): Mengambil 110 titik data setelah puncak R. Durasi ini (± 306 ms) dialokasikan lebih panjang untuk memastikan segmen ST dan gelombang T tertangkap sepenuhnya, karena kelainan pada repolarisasi ventrikel sering terjadi pada fase ini.

3. Penanganan Tepi (*Padding*): Untuk detak jantung yang berada di awal atau akhir rekaman di mana jumlah sampel tidak mencukupi (kurang dari 90 sebelum atau 110 sesudah R-peak), dilakukan teknik *zero-padding* untuk memastikan dimensi output tetap konsisten di angka 200 sampel.

Hasil dari segmentasi dan ekstraksi dari sinyal dapat terlihat pada **Gambar 3.2**.



Gambar 3.2 Segmentasi dan Ekstraksi Sinyal


3.2.3. Pembentukan *Window Construction*

Berbeda dengan metode konvensional yang mengklasifikasikan setiap detak secara terisolasi, penelitian ini menerapkan pendekatan *Context-Aware* untuk menangkap pola temporal antar-detak. Data input dibentuk menjadi jendela konteks (*context window*) dengan spesifikasi sebagai berikut:

1. Ukuran Jendela (Window Size): Setiap input model terdiri dari 7 detak berurutan.

- a. Komposisi: 3 detak sebelumnya (*previous beats*), 1 detak pusat (*center beat*), dan 3 detak setelahnya (*subsequent beats*).
 - b. Tujuan: Konfigurasi ini memungkinkan model untuk mempelajari pola ritme jangka panjang, seperti pada kasus *Bigeminy* (setiap detak kedua abnormal) atau *Trigeminy*, yang sulit dideteksi jika hanya melihat satu detak saja.
2. Penentuan Label: Label klasifikasi (Normal/Abnormal) untuk satu jendela konteks ditentukan berdasarkan label dari detak pusat (urutan ke-4 dalam jendela). Detak-detak di sekitarnya hanya berfungsi sebagai fitur pendukung (konteks) dan tidak mempengaruhi label target secara langsung.

Hasil dari pembentukan *windows construction* ini dapat dilihat pada **Gambar 3.3**.



Gambar 3.3 *Windows Construction*

3.2.4 Dataset Final dan Labeling

Hasil akhir dari proses segmentasi dan pembentukan jendela adalah himpunan data tensor dengan dimensi (Jumlah Sampel, 7, 200).

- a. Dimensi 7: Merepresentasikan *channels* yang berisi 7 detak dalam satu jendela.
- b. Dimensi 200: Merepresentasikan panjang sampel (*sequence length*) per detak.

Target klasifikasi disederhanakan menjadi dua kelas (biner) sesuai kebutuhan klinis untuk *screening* awal:

- a. Kelas 0 (Normal): Mencakup anotasi 'N' (*Normal Sinus Rhythm*).
- b. Kelas 1 (Abnormal): Menggabungkan seluruh jenis aritmia lainnya (termasuk *Premature Ventricular Contraction*, *Atrial Premature Beat*, *Bundle Branch Block*, dll).

3.3 Pra-pemrosesan dan Analisis Kualitas Data

Setelah dataset telah terkumpul dan terbentuk pada satu file, tahapan berikutnya adalah analisis mengenai karakteristik sinyal dan menentukan penanganan kualitas data. Pada sub-bab ini akan dijabarkan bagaimana representasi dari data serta evaluasi terhadap outlier untuk memastikan informasi yang masuk ke dalam model yang digunakan.

3.3.1 Karakteristik fisik dan dimensi data

Data yang tersimpan pada matriks dataset dijabarkan mengenai makna dari setiap sumbu data berdasarkan spesifikasi teknis MIT-BH. Data yang terekam pada dataset terbagi menjadi 2 yaitu:

- a. Sumbu Waktu (Time Axis) Sumbu horizontal merepresentasikan urutan pengambilan data. Data rekaman digital ini memiliki frekuensi sampling sebesar 360Hz. Oleh karena itu, interval waktu antar titik data dapat dihitung dengan **persamaan 10** :

$$\Delta t = \frac{1}{f_s} = \frac{1}{360} \approx 2.78ms \quad (10)$$

Ini menandakan setiap kolom memiliki jarak waktu sekitar 2.78 milidetik. Total durasi window time untuk satu baris data ditunjukkan oleh **persamaan 11**

$$T_{window} = 200 \times 2.78ms \approx 556ms \quad (11)$$

Durasi sekitar 0,52 detik ini dipilih karena ideal dalam menangkap satu detak jantung secara utuh tanpa ada banyak gangguan dari detak lainnya

- b. Sumbu Amplitudo (Amplitudo Axis) Sumbu vertikal pada merepresentasikan amplitudo pada setiap detak jantung. Data yang digunakan pada penelitian ini adalah nilai mentah (raw values) yang diperoleh dari konversi nilai ADC dengan resolusi 11-bit. Resolusi ini membagi tegangan yang masuk dengan total tegangan sebesar 10mV menjadi 2048 level diskrit.

Oleh karena itu, resolusi tegangan per satuan (LSB) dapat dihitung pada **persamaan 12**.

$$LSB = \frac{Rentang\ Tegangan\ Total}{Level\ Diskrit} = \frac{10mV}{2048} \approx 0,0048mV/unit \quad (12)$$

Dikarenakan karakteristik sinyal pada dataset ini mempunyai titik tengah pada nilai 1024, maka konversi dari nilai raw digital (X_{raw}) menjadi satuan milivolt (mV) pada diformulasikan pada **persamaan 13**.

$$mV = (X_{raw} - 1024) \times 0,0048 \quad (13)$$

Berdasarkan persamaan diatas, rentang nilai mentah yang diamati pada dataset yaitu pada rentang 910 – 1200 yang merepresentasikan variasi amplitudo. Maka, nilai 910 setara dengan -0,56mV sedangkan 1200 setara dengan +0,86mV dimana rentang ini mencakup naik turun sinyal detak jantung dari baseline hingga R-Peak pada satu siklus detak jantung.

3.3.2 Pemisahan Data

Penelitian ini tidak menggunakan pemisahan acak per detak (*random beat-wise split*) karena metode tersebut berisiko mencampurkan detak dari pasien yang sama ke dalam data latih dan data uji, yang menyebabkan bias evaluasi yang terlalu optimis. Oleh karena itu, diterapkan strategi lain yaitu Record-wise Split yang berupa :

1. Metode Pembagian: Dataset dibagi berdasarkan Nomor Rekaman (Record ID) pasien. Artinya, jika seorang pasien masuk ke dalam data latih, maka seluruh detak jantungnya hanya berada di data latih dan tidak akan muncul di data validasi maupun uji. Hal ini mensimulasikan kondisi dunia nyata di mana model akan memproses pasien baru yang belum pernah dilihat sebelumnya.
2. Proporsi Pembagian: Dataset total (47 rekaman) dibagi dengan proporsi untuk pelatihan, validasi, dan pengujian.

3.3.3 Normalisasi Data

Normalisasi dilakukan untuk menyeragamkan rentang amplitudo sinyal agar mempercepat konvergensi model. Proses ini dilakukan dengan aturan ketat untuk menjaga integritas data uji:

- a. Metode: Menggunakan *Standard Scaler* yang mengubah distribusi data memiliki rata-rata 0 dan standar deviasi 1
- b. Prosedur *No-Peeking*: *Scaler* hanya dilatih (*fit*) menggunakan data Training. Parameter rata-rata dan standar deviasi yang diperoleh dari data Training kemudian digunakan untuk mentransformasi data Validasi dan Test. Hal ini mencegah kebocoran statistik dari data uji ke dalam model.
- c. Implementasi Teknis: Data input 3D (Jumlah Sampel, 7, 200) diratakan (*flatten*) menjadi (Jumlah Sampel, 1400) terlebih dahulu sebelum normalisasi untuk memastikan konsistensi statistik di seluruh jendela konteks, kemudian dibentuk kembali (*reshape*) ke dimensi asli sebelum masuk ke model.

3.4 Perancangan model 1D-CNN

3.4.1. Kebutuhan model

Berdasarkan tinjauan pustaka, 1D-CNN sangat sesuai untuk data deret waktu seperti sinyal ECG karena kemampuannya dalam mengekstraksi fitur spasial dan temporal secara otomatis dari data mentah (Ahmed et al., 2023). Model ini diharapkan dapat menangani variasi dalam bentuk gelombang detak jantung dan mengidentifikasi pola-pola yang membedakan detak jantung Normal dan Abnormal.

3.4.2. Perancangan arsitektur 1D-CNN

Arsitektur model akan dirancang dengan mempertimbangkan efektivitas dan efisiensi. Rancangan umum akan mencakup urutan lapisan konvolusi 1D, *pooling*, dan *dense layer* (lapisan *fully connected*). Lapisan Konvolusi 1D: Beberapa lapisan konvolusi 1D akan digunakan untuk mengekstraksi fitur hierarkis dari sinyal detak jantung. Setiap lapisan konvolusi akan memiliki jumlah *filter* tertentu (misalnya, 64, 128, 256) dan ukuran *kernel* yang bervariasi (misalnya, 3, 5, 10) untuk menangkap pola lokal dengan skala berbeda. Fungsi aktivasi ReLU (Rectified Linear Unit) akan diterapkan setelah setiap lapisan konvolusi.

1. Lapisan *Pooling*: Setelah kelompok lapisan konvolusi, lapisan *Max-Pooling 1D* akan digunakan untuk mengurangi dimensi spasial, menyorot

fitur paling menonjol, dan membuat model lebih robust terhadap variasi posisi fitur (Ahmed et al., 2023).

2. Lapisan *Batch Normalization*: Lapisan ini akan disisipkan untuk menstabilkan proses pelatihan dan mempercepat konvergensi dengan menormalisasi *input* ke setiap lapisan pada setiap *mini-batch* (Ahmed et al., 2023).
3. Lapisan *Dropout*: Untuk mencegah *overfitting*, lapisan *Dropout* akan ditambahkan pada beberapa titik dalam arsitektur, secara acak "mematikan" sebagian neuron selama pelatihan (Ahmed et al., 2023).

Lapisan *Dense (Fully Connected)*: Setelah fitur diekstraksi oleh lapisan konvolusi dan dipipihkan (*flatten*), beberapa lapisan *Dense* akan digunakan untuk melakukan klasifikasi akhir. Lapisan *output* akan menggunakan fungsi aktivasi Sigmoid untuk klasifikasi biner (Normal/Abnormal).

3.5 Pelatihan dan skenario pengujian model

Pada tahapan ini akan merinci konfigurasi secara teknis yang diterapkan selama proses pembelajaran model serta strategi validasi yang akan digunakan dalam menguji model sebelum nanti akan diimplementasikan pada system.

3.5.1 Konfigurasi Hiperparameter (*Hyperparameters*)

Berdasarkan karakteristik dataset yang memiliki ketimpangan kelas dan kompleksitas fitur, konfigurasi pelatihan ditetapkan sebagai berikut:

1. *Loss Function* : Penelitian ini menerapkan Cross Entropy Loss dengan mekanisme Class Weights. Mengingat jumlah data kelas normal jauh lebih dominan dibandingkan kelas abnormal, bobot penalty yang lebih besar akan diterapkan pada kesalahan prediksi pada kelas abnormal. Pendekatan ini bertujuan untuk mencegah model menjadi bias terhadap kelas mayoritas dan meningkatkan sensitivitas terhadap deteksi aritmia.
2. *Optimizer* “ Algoritma Adam W dipilih sebagai pengoptimal dengan learning rate awal sebesar 0.0001 dan weight decay sebesar $1e-4$. Pemilihan AdamW didasarkan pada kemampuannya yang mampu memisahkan bobot dari pembaruan gradien, yang terbukti menghasilkan generalisasi yang lebih baik dibandingkan dengan Adam standar pada model Deep Learning.
3. Mekanisme Kendali Pelatihan:

- a. Penjadwalan (*Scheduler*) : Menggunakan *ReduceLRONPlateau* yang secara otomatis menurunkan laju pembelajaran jika metrik AUC pada data validasi stagnan selama 5 epoch berturut-turut. Hal ini memungkinkan model untuk melakukan penyesuaian bobot yang lebih halus saat mendekati titik konvergensi.
- b. *Early Stopping* : Proses training akan dihentikan secara otomatis jika tidak terjadi peningkatan kinerja pada data validasi selama 15 epoch. Mekanisme ini krusial untuk mencegah terjadinya overfitting.

3.5.2 Skenario Pengujian Sistem

Selain evaluasi menggunakan data uji, validasi model ini diperkuat dengan simulasi system pada bagian *frontend*. Pengujian ini akan menggunakan 1 dataset secara acak yang tidak dimodifikasi sama sekali dari awal. Tujuan penggunaan dataset khusus ini adalah untuk menguji ketahanan model terhadap data pasien baru yang belum pernah terlihat sama sekali sebelumnya serta memverifikasi kinerja model saat memproses data menggunakan mekanisme *Rolling Buffer*. Skenario ini dirancang untuk merepresentasikan kondisi tantangan nyata pada alat pemantuann.

3.6 Arsitektur dan Implementasi Sistem

Untuk merubah model klasifikasi menjadi alat bantu yang aplikatif, penerlitian ini merancang arsitektur software yang memisahkan *backend* dan *frontend*.

3.6.1 Logika Backend

Komponen pada *backend* berfungsi sebagai mesin pemrosesan data yang beroperasi dilatar belakang system. Alur kerja teknis pada komponen ini nantinya meliputi:

1. Data Buffering : Sistem dirancang untuk menerima aliran *raw data* secara terus menerus. Mengingat model ini membutuhkan konteks temporal maka data tidak akan diproses per titik detak jantung melainkan ditampung pada *Rolling Buffer* berkapasitas 7 detik. Prediksi baru akan dilakukan hanya ketika window lengkap telah terbentuk untuk menjadi validitas input dari model.
2. Pra-pemrosesan terstandarisasi : Data Buffering tadi dinormalisasikan secara real-time menggunakan parameter statistic yang identic dengan data training. Konsistensi Teknik pra-pemrosesan ini vital untuk menjaga akurasi inferensi.

3. Inferensi model ONNX : Eksekusi prediksi dilakukan menggunakan format model ONNX. Penggunaan model ini dipilih karena efisiensi memori dan kecepatan eksekusi yang lebih tinggi dibandingkan memuat *training library* secara utuh, sehingga lebih optimal untuk *deployment*.

3.6.2 Visualisasi Frontend

Komponen frontend bertugas untuk menampilkan hasil analisis komputasi menjadi informasi visual yang interaktif bagi pengguna medis. Fitur utama dari antarmuka meliputi:

- a. *Load Patient Data* Untuk menampung fungsi pemuatan data, antarmuka menyediakan *control panel* pada bagian atas yang akan memfasilitasi user dalam mengatur *input stream* melalui tombol navigasi serta pengaturan untuk kecepatan dari sampling. Panel ini nantinya akan berfungsi sebagai *trigger* bagi sistem *backend* untuk memulai mengisi *rolling buffer* sebelum data diproses oleh model
- b. *Monitoring ECG Signal* Fungsi pemantauan sinyal ini diimplementasikan melalui grafik utama berbasis waktu yang bergerak secara *real-time*. Visualisasi ini menggambarkan aktivitas dari jantung secara terus menerus. Untuk mendukung validasi oleh user, grafik ini dilengkapi dengan *marker* otomatis pada setiap *R-Peak* yang berhasil dideteksi.
- c. *View Diagnosis Result* Hasil model yang sudah ada ditampilkan kepada user melalui indikator visual untuk mendukung pengambilan Keputusan dimana fitur ini mencakup status klasifikasi baik normal atau abnormal, visualisasi probabilitas dan *beat snapshot*.

3.7 Perancangan Fungsional Sistem (Use Case)

Interaksi fungsional antara user dan system dimodelkan dengan menggunakan *Use Case Diagram*. Diagram ini bertujuan untuk memvisualisasikan bagaimana user nantinya akan berinteraksi dengan interface aplikasi untuk melakukan pemantauan dan deteksi aritmia. Pendekatan ini nantinya akan memastikan bahwa ada Batasan pada system dan hak akses user dengan jelas sebelum implementasi kode dilakukan.


3.7.1 Definisi Aktor

Aktor pada system ini didefinisikan sebagai *User* atau pengguna. User ini nantinya akan merepresentasikan operator ataupun tenaga medis yang akan bertanggung jawab untuk mengoperasikan aplikasi pemantauan. Dalam konteks

simulasi ini, user akan memiliki akses penuh terhadap seluruh fitur dari system tanpa memerlukan otentifikasi, guna memfasilitasi proses demo dan pengujian secara cepat.

3.7.2 Use Case Diagram

Berdasarkan analisis dari kebutuhan fungsional pada sistem, terdapat tiga aktivitas utama yang dapat dilakukan oleh aktor. Hubungan antara aktor dengan fungsionalitas sistem dapat terlihat pada **Gambar 3.4**.



Gambar 3.4 Use Case Diagram

3.7.3 Deskripsi Skenario Use Case

Pada bagian ini, akan dijelaskan secara rinci mengenai interaksi antara user dengan sistem dan spesifikasi untuk setiap kasus penggunaannya. Penjelasan setiap kasusnya adalah sebagai berikut:

1. Memuat Data Pasien : Fungsi ini nantinya memungkinkan user untuk memuat system dan memilih sumber data rekaman ECG yang akan dianalisis. Alur kerja dari system ini adalah system memuat dataset pengujian dan membaca anotasi secara otomatis. Sistem kemudian menyiapkan mekanisme Rolling Buffer untuk memulai aliran data sinyal

2. Memantau Sinyal ECG : Fungsi ini nanti memberikan feedback visual kepada user berupa grafik detak jantung yang bisa diperbarui secara *real-time*. Alur kerja dari system ini adalah mengambil data dari buffer dan rendering grafik gelombang yang bergerak dari kiri ke kanan pada layer interface. User dapat mengamati perubahan sinyal ini secara visual untuk memverifikasi pembacaan sensor.
3. Melihat hasil diagnosis : Fungsi ini nantinya akan menyajikan hasil analisis model kepada user untuk mendukung pengambilan Keputusan. Alur kerjanya adalah setelah model melakukan prediksi pada detak jantung yang terdeteksi, system akan menampilkan status teks baik normal maupun abnormal dan mengubah warna indikator grafik yaitu biru untuk normal dan merah untuk abnormal. User akan menerima informasi ini secara langsung tanpa perlu melakukan apapun dan bisa mengambil Keputusan berdasarkan hasil pengujian pada uji model tersebut