

BAB 4

HASIL DAN PEMBAHASAN

4.1 Lingkungan Pengembangan

Model 1D-CNN V6 dilatih menggunakan *framework* PyTorch versi 2.6.0 dengan akselerasi GPU (CUDA 12.4). Spesifikasi lingkungan komputasi yang ddigunakan adalah:


- Platform : Python 3.10
- Hardware Akselerator : NVIDIA GPU (CUDA)
- Optimasi : Penggunaan Mixed Precision Training untuk efisiensi memori.
- Inference Engine* : ONNX Runtime

4.2 Hasil dan Evaluasi Data Modifikasi

Implementasi pra-pemrosesan data adalah tahapan krusial yang menentukan batas dari kinerja model. Pada penelitian ini, dataset mentah (*raw data*) MIT-BIH Arrhythmia Database telah dimodifikasi melalui beberapa proses dengan segmentasi berbasis *R-Peak* dan pembuatan *context windows*. Pada bab ini disajikan analisis statistic terhadap data yang dihasilkan serta evaluasi terhadap strategi modifikasi yang telah diterapkan.

4.2.1 Analisis Distribusi Dataset Final

Berdasarkan tahapan ekstrasi fitur yang telah diuraikan pada metodologi, proses segmentasi terhadap 47 rekaman sinyal menghasil total data sebanyak 108.090 sampel detak jantung. Kualitas distribusi data ini menjadi Langkah awal untuk mengukur potensi bias pada model dan distribusi kelas disajikan pada **Gambar 4.1**



Gambar 4.1 Distribusi Dataset Final

Terlihat pada gambar diatas, terdapat ketimpangan atau *imbalance* yang mencolok antara kelas mayoritas dan minoritas. Rincian kuantitatif dari dari distribusi kelas tersebut diuraikan pada **Tabel 4.1**.

Tabel 4.1 Distribusi Dataset Final

Kelas Klasifikasi	Jumlah Sampel	Proporsi
Kelas 0 (Normal)	73.443	67,9%
Kelas 1 (Abnormal)	34.647	32,1%
Total Sampel	108.090	100%

Dari tabel diatas tersebut menunjukkan bahwa kelas Normal mendominasi populasi data hingga 67.8%. Dalam pandangan *Deep Learning*, kondisi ini dapat menimbulkan resiko yang menyebabkan model cenderung akan memprediksi seluruh input sebagai Normal untuk meminimalkan nilai *Loss* secara umum tanpa benar-benar mempelajari fitur dari kelas Abnormal. Temuan ini akan menjadi landasan justifikasi penerapa strategi *class weighting* yang akan dibahas pada sub-bab berikutnya.

4.2.2 Evaluasi *Context Window* (7-Beat)


Penelitian ini mengajukan hipotesis bahwa analisis aritmia tidak dapat dilakukan secara optimal hanya dengan meninjau dari detak jantung tunggal. Oleh karena itu, diterapkan struktur input *context window* selebar 7 detak. Hasil dari modifikasi dataset setelah mengalami *context window* tersaji pada **Tabel 4.2**.

Tabel 4.2 Total Proporsi *Context Window*

47 Record	Jumlah	Proporsi
Normal	73.315	67.94%
Abnormal	34.587	32.06%
Total	107.902	100%

Sebagai contoh juga, pada record 221 dilakukan ilustrasi proses pendekatan *context window* yang dimana model tidak menerima detak pusat sebagai input

tunggal, namun juga menyertakan 3 detak sebelumnya dan 3 detak setelahnya yang ditampilkan pada **Gambar 4.2**



Gambar 4.2 Context Window pada record 221

Pendekataan *context window* ini memberikan beberapa keuntungan analisis utama:

- a. Pemahaman pola : Aritmia kompleks seperti *Bigeminy* memiliki pola ritme yang bergantian. Dengan melihat detak jantung sebelum dan sesudahnya, model dapat mengenali pola pengulangan tersebut dimana jika hanya melihat detak pusat tidak mungkin untuk dilakukan.
- b. Validasi Morfologi : Area konteks ini berfungsi sebagai *baseline*. Jika detak jantung pusat mengalami deformasi akibat noise, model dapat membandingkan dengan detak jantung sebelah kiri untuk menentukan apakah itu aritmia atau memang hanya gangguan dari sinyal.

4.2.3 Analisis Record Wise Split

Strategi pembagian dari dataset dilakukan dengan metode *record-wise Split*. Metode ini dipilih untuk menjamin integritas evaluasi serta mencegah terjadi kebocoran data atau *data leakage* yang sering muncul pada metode sederhana.


Dengan membagi data berdasarkan ID rekaman pasien, sistem memastikan bahwa data latih, validasi dan uji tersebut berasal dari Kumpulan subjek yang benar-benar terpisah, sehingga hasil evaluasi akhir merepresentasikan kemampuan model yang valid. Rincin kuantitati dari hasil pembagian tersebut terdapat pada **Tabel 4.3**.

Tabel 4.3 Sebaran *Record Wise Split*

Pembagian Data	Jumlah Split	Persentase	Rincian Kelas Normal	Rincian Kelas Abnormal
<i>Training Set</i>	75.804	70,3%	54.685	21.119
<i>Validation Set</i>	14.436	13,4%	5.722	8.714
<i>Test Set</i>	17662	16,4%	12.908	4.754
Total	107.902	100%	73.315	34.587

Berdasarkan tabel tersebut, dominasi alokasi data difokuskan pada *Training Set* dengan total data sebanyak 75.804 yang mencakup 54.685 sampel normal dan 21.119 sampel abnormal dengan proporsi sebesar 70,3%. Alokasi ini bertujuan untuk memberikan basis pengetahuan yang cukup bagi model dalam mempeleajari fitur pembeda. Sedangkan, *Validation Set* mencakup 14.436 data atau 13.4% yang berfungsi sebagai validator internal selama *training*, dan *Test Set* terdiri total 17.622 data atau 16,4% yang disiapkan sepenuhnya sebagai simulasi data pasien baru.

Untuk memberikan Gambaran yang lebih nyata, sebaran data tersebut divisualisasikan pada **Gambar 4.3**.



Gambar 4.3 Proporsi *Record Wise Split*

Gambar tersebut menegaskan bahwa meski pembagian data dilakukan secara ketat berdasarkan pasien yang memiliki variabilitas kondisi, distribusi kelas normal dan abnormal tetap terwakili secara utuh di ketiga bagian tersebut. Secara khusus, total 4.754 sampel abnormal pada *Test Set* adalah indikator penting bahwa pengujian model dilakukan pada himpunan data yang substantial, bukan pada sampel yang terbatas.

4.2.4 Analisis Penerapan Class Weighting

Tantangan lain yang terlihat dari statistik dataset adalah karakteristik dari distribusi yang tidak seimbang (*imbalanced dataset*). Jika dilihat pada diagram distribusi sebelumnya, kelas normal mendominasi populasi data sebesar 67,9% jika dibandingkan dengan kelas abnormal yang hanya 32,1%. Ketidakseimbangan jumlah data ini dapat berpotensi menyebabkan model mengalami bias mayoritas, dimana model memiliki akurasi yang tinggi namun gagal untuk mengenali kasus penyakit yang sebenarnya.

Untuk mengatasi masalah bias tersebut, pada penelitian ini memakai strategi pembobotan kelas atau *Class Weighting*. Berdasarkan sebaran data yang ada, bobot penalty dikalkulasi secara invers dan dihasilkan nilai sebesar 0,73 untuk kelas normal dan 1,56 untuk kelas abnormal.

Pemberian bobot yang cenderung lebih besar kepada kelas abnormal bertujuan untuk memberikan penalty atau *Loss* yang lebih berat bagi model apabila gagal dalam mendeteksi aritmia proses *training*. Mekanisme ini nantinya akan memaksa model untuk lebih memprioritaskan pembelajaran fitur pada kelas minoritas, sehingga diharapkan bisa menghasilkan nilai sensitivitas (*Recall*) yang tinggi pada hasil evaluasi akhir.

4.3 Hasil dan Evaluasi Data Model

Setelah melalui tahapan pelatihan, performa model dievaluasi menggunakan data uji atau *Test Set* yang terdiri dari 17.662 *context windows*. Penting untuk diketahui bahwa data uji ini berasal dari rekaman pasien yang baru dan terpisah sepenuhnya, sehingga hasil evaluasi dari kemampuan model itu objektif.

4.3.1 Evaluasi Kinerja Model

Hasil dari pengujian biner pada data uji dapat tersaji pada **Tabel 4.4** . Indikator kinerja tersebut diukur berdasarkan empat indikator standar yaitu akurasi, presisi, sensitivitas(*Recall*), dan *F1-Score*.


Tabel 4.4 Hasil Evaluasi Model 1D-CNN

Indikator Evaluasi	Nilai	Persentase
Akurasi (Accuracy)	0.9803	98.03%
Presisi (Precision)	0.9816	98.16%
Sensitivitas (recall)	0.9882	98.82%
F1-Score	0.9849	98.49%
AUC-ROC	0.9993	99.93%

Berdasarkan rekapitulasi data yang terlihat pada tabel 4.1, model 1D-CNN yang dikembangkan menunjukkan kinerja klasifikasi yang andal data Data Uji. Tingkat akurasi yang mencapai 98.03% mengindikasikan bahwa model tersebut dapat mempelajari pola fitur morfologis sinyal ECG dengan sangat baik dan menggeneralisasikannya pada data yang belum pernah dilihat sebelumnya. Namun, dalam konteks diagnosis biomedis, akurasi semata tidak cukup untuk menggambarkan bagaimana system itu aman. Oleh karena itu, nilai *recall* sebesar 98.82% menjadi temuan yang signifikan pada evaluasi ini. Angka tersebut menggambarkan kemampuan model pada meminimalisir kesalahan *False Negative*, yang berarti sistem mempunyai tingkat kepekaan yang tinggi dalam menangkap keberadaan aritmia dan mencegah pasien untuk tidak terdiagnosis. Keandalan ini juga diperkuat oleh *F1-Score* sebesar 98.49% yang menandakan adanya keseimbangan antara presisi dan sensitivitas, sehingga model tidak mengalami bias terhadap salah satu kelas. Selain itu, nilai AUC-ROC sebesar 99.93% menandakan bahwa system memiliki *decision boundary* yang tegas dan stabil dalam memisahkan sinyal jantung normal dan abnormal pada berbagai kondisi ambang batas.

4.3.2 Analisis *Training Convergence*

Kualitas dari proses pembelajaran model dapat divalidasi melalui grafik fungsi *Loss* dan akurasi selama proses *training*. Visualisasi model ini terdapat pada gambar.




Gambar 4.4 Grafik Loss dan Akurasi pada Data Latih dan Validasi

Dari grafik diatas tersebut, dapat ditarik analisis ilmiah sebagai berikut:

- Stabilitas Model : Kurva *Validation Loss* yang ditunjukkan warna oranye bergerak seirama dengan *Training Loss* dengan warna biru dengan jarak yang sangat tipis. Hal ini membuktikan bahwa mekanisme anti-*overfitting* yang diterapkan seperti Dropout 0.5, *weight decay*, dan *Batch Normalization* bekerja dengan efektif.
- Early Stopping*: Pelatihan dihentikan secara otomatis pada epoch ke-41 oleh mekanisme *Early Stopping* karena model tidak dapat lagi menunjukkan penurunan *loss* yang signifikan. *Checkpoint* model terbaik disimpan pada epoch ke-26 dengan akurasi validasi sebesar 99.06%.

4.3.3 Analisis *Confusion Matrix*

Untuk membedah hasil dan detail dari kesalahan prediksi, maka digunakan *Confusion Matrix* pada data uji yang ditampilkan pada **Gambar 4.5**



Gambar 4.5 Analisa *Confusion Matrix*

Analisa sebaran prediksi dari total 10809 data uji:

- True Normal (TN) : 7281 detak (Prediksi Normal, Aktual Normal).
- True Abnormal (TP) : 3424 detak (Prediksi Abnormal, Aktual Abnormal).
- False Positive (FP) : 64 detak (Terdeteksi Aritmia, Aktual Normal).
- False Negative (FN) : 41 detak (Terdeteksi Normal, Aktual Aritimia).

Dalam konteks diagnose medis, nilai False Negative (FN) adalah tolak ukur yang paling kritis karena berkaitan dengan resiko pasien yang tidak terdiagnosis. Jumlah FN yang sangat rendah yaitu 41 dari 3.464 kasus abnormal menunjukkan sensitivitas yang tinggi dari system.

4.4 Implementasi Sistem

Setelah model 1D-CNN berhasil divalidasi dengan metrik performa yang memadai, tahapan penelitian dilanjutkan dengan integrasi model ke dalam *software* yang fungsional. Implementasi ini bertujuan untuk membuktika jika model yang dilatih menggunakan data baru mampu beradaptasi dan bekerja secara responsif dalam skenario pemantauan detak jantung secara *real-time*. Sistem ini dibangun dengan memisahkan logika *backend* dan *frontend* untuk menjamin efisiensi pada komputasi.

4.4.1 Mekanisme Inferensi dan *Rolling Buffer*


Salah satu tantangan pada fase *deployment* ini adalah perbedaan dari input. Data dari pasien masuk secara satu per satu, sedangkan model yang dikembangkan membutuhkan input berbasis 7 detak. Untuk mengatasi ini, sistem menerapkan *rolling buffer*.

Secara teknis, sistem tidak langsung melakukan prediksi pada setiap data yang masuk. Sebaliknya, sistem mengelola *buffer* yang menampung 7 detak jantung terakhir. Mekanisme ini bekerja dengan prinsip FIFO, saat detak baru terdeteksi, detak lama akan terhapus. Inferensi ke ONNX Runtime hanya akan terjadi saat *buffer* telah terisi penuh. Langkah ini memastikan bahwa setiap model dipanggil, ia selalu menerima data yang utuh yaitu 3 detak sebelumnya, 1 detak pusat dan 3 detak setelahnya sehingga akurasi prediksi ritme seperti pada kasus *Bigeminy* tetap terjaga meskipun dalam mode *streaming*.

Selain itu, untuk menjaga konsistensi dari data, model pada sisi *backend* menerapkan parameter normalisasi yang identik dengan data latih. Hal ini untuk mencegah distorsi nilai fitur yang bisa menurunkan performa dari model pada saat dijalankan pada *runtime*.

4.4.2 Antarmuka Pemantauan *Real-Time*

Untuk memvalidasi kegunaan dari model yang sudah dibuat, dikembangkan antarmuka berbasis web (*Dashboard*) yang mensimulasikan penggunaan dari proyek penelitian ini. Tampilan antarmuka saat sistem mendeteksi aritmia ditunjukkan pada **Gambar 4.6**.



Gambar 4.6 Tampilan *Frontend*

Berdasarkan pengujian fungsional pada gambar diatas, sistem berhasil menampilkan beberapa hal sebagai berikut:

- a. Panel Kontrol dan Metrik Fisiologis Pada bagian atas, terdapat panel navigasi yang memungkinkan *user* untuk mengatur simulasi data, termasuk fitur pengaturan kecepatan untuk keperluan analisis yang lebih mendalam. Panel ini juga menampilkan kalkulasi dari BPM (*Beats Per Minute*) yang dihitung dari rata-rata interval 10 detak terakhir. Perhitungan ini dilengkapi dengan filter otomatis untuk mengabaikan interval tidak wajar akibat noise.
- b. Visualiasi Sinyal Grafik utama menampilkan sinyal yang bergerak secara *real-time* kiri ke kanan yang menyerupai monitor pasien standar. Sistem menerapkan penandaan visual pada setiap *R-Peak* menggunakan warna Hijau untuk detak normal dan titik Merah untuk indikasi Abnormal yang dapat memudahkan identifikasi cepat secara visual.
- c. *Current Beat Snapshot* Panel Tengah berfungsi sebagai fitur transparansi. Panel ini akan menampilkan potongan sinyal sepanjang 200 sampel yang sedang diproses oleh model pada saat itu juga. Fitur ini memungkinkan dokter untuk bisa memverifikasi apakah bentuk gelombang yang dideteksi oleh sistem itu valid secara morfologi atau itu hanyalah sekedar gangguan pada sinyal.
- d. Panel Diagnosa dan Peringatan Panel bawah menyajikan status akhir dari sistem. Indikator akan berubah menjadi teks “ABNORMAL” berwarna merah yang disertai dengan nilai probabilitas Ketika prediksi model ini melampaui ambang batas dari keamanan. Peringatan visual ini juga dirancang untuk menarik perhatian dari tim medis secepat mungkin.
- e. *Classification History* Pada sisi kanan, terdapat panel *log* yang merekam Riwayat dari klasifikasi detak jantung. Fitur ini berfungsi sebagai audit yang klinis dan memungkinkan *user* untuk *back tracing* Riwayat diagnosis pasien guna meninjau kapan tepatnya aritmia terjadi selama sesi pemantauan.

4.5 Pengujian Sistem

Pengujian sistem dilakukan untuk menverifikasi fungsional dari *software* sebelum diterapkan pada skenario kasus nyata. Metode yang digunakan pada sistem kali ini adalah *Blackbox Testing*, yang berfokus pada validasi *input-output* fungsi tanpa melihat struktur dari kode internal. Pengujian ini bertujuan untuk memastikan bahwa seluruh fitur antarmuka dan logika kontrol dapat berjalan sesuai dengan rancangan. Hasil pengujian fungsional terhadap fitur utama sistem tersebut ditunjukkan pada **Tabel 4.5**.

Tabel 4.5 *Black Box Testing*

Skenario Pengujian	Aktivitas Pengujian	Hasil yang diharapkan	Hasil Aktual	Status
Inisialisasi dan <i>Load Data</i> Pasien	<i>User</i> memilih dataset dan menekan tombol start pada <i>control panel</i>	Sistem dapat membaca sumber data, inisialisasi <i>buffer</i> , dan grafik sinyal mulai bergerak	Grafik dapat bergerak dan data pasien baru berhasil untuk dimuat	Valid
Kontrol Aliran Data	<i>User</i> dapat mengubah parameter kecepatan dan menekan tombol stop	Laju <i>scrolling</i> grafik berubah sesuai dengan input dan berhenti total saat tombol stop ditekan	Kecepatan sangat responsive dan grafik berhenti	Valid
Validasi Deteksi Normal	Sistem memproses data yang dianotasi sebagai detak jantung yang normal	Indikator status berwarna Hijau dan teks menampilkan status “NORMAL”	Indikator sesuai dengan warna Ketika Normal	Valid
Validasi Deteksi Abnormal	Sistem memproses data yang dianotasi sebagai detak jantung yang abnormal	Indikator status berwarna Merah dan teks menampilkan status “Abnormal”	Indikator sesuai dengan warna Ketika Normal	Valid

Validasi Perhitungan BPM	Sistem mendeteksi detak jantung dengan interval pendek	Algoritma BPM mengabaikan interval $<0.3s$ dan angka BPM tetap stabil	Angka BPM stabil dan logis secara fisiologis	Valid
Navigasi Log Kesalahan	Model melakukan prediksi yang salah	Sistem mencatat waktu kejadian pada panel dan saat diklik, grafik melompat ke posisi tersebut	Kesalahan tercatat dan navigasi berfungsi akurat	Valid
Stabilitas Skala Grafik	Sistem memproses detak jantung dengan amplitude tinggi dan diikuti dengan amplitudo rendah	Skala Y-axis grafik menyesuaikan dengan nilai maksimum dan tidak mengecil agar tampilan stabil	Grafik terlihat stabil dan nyaman saat dilihat oleh mata	Valid
Eksport Data Otomatis	<i>User</i> menjalankan simulasi lalu menekan tombol Stop dan download	Sistem mengunduh file .ZIP berisi gambar hasil diagnosis setiap 2 menit	File Zip berhasil diunduh lengkap	Valid
Audit Log	Klik Pada salah satu	Grafik utama mundur pada	Navigasi berfungsi akurat	Valid

	<i>Classification History</i>	kejadian tersebut		
--	-----------------------------------	----------------------	--	--

Berdasarkan tabel diatas tersebut, seluruh fitur yang ada dinyatakan Valid, yang menandakan sistem siap digunakan untuk tahap implementasi pada sebuah kasus.

4.6 Contoh Implementasi (Case Study)

Validitasi dari sebuah sistem diagnosis medis tidak hanya di tentukan oleh metrik evaluasi pada data uji standar, namun lebih jauh lagi yaitu pada kemampuannya beradaptasi pada variabilitas biologis antar pasien yang belum pernah dipelajari sebelumnya (*Unseen Data*). Untuk mengukur kapabilitas tersebut, dilakukan simulasi implementasi menggunakan sebuah data record dari MIT-BH yang belum dimodifikasi sama sekali. Rekaman ini dipilih secara acak tanpa sama sekali modifikasi didalamnya dan sepenuhnya tersisolasi dari proses pelatihan maupun validasi. Serta memiliki karakteristik sinyal dengan kompleksitas tinggi yang merepresentasikan contoh tidak pasti dari kondisi klinis pada dunia nyata. Proses sistem dalam menangani proses data tersebut digambarkan pada **Gambar 4.7**.



Gambar 4.7 Potongan Proses Data

Pada gambar diatas, diambil potongan potongan proses data dari data uji yang masuk ke dalam model tersebut pada menit keempat dan dua puluh satu detik.

Potongan tersebut memperlihatkan bahwa terdapat proses pencarian *R-Peak* dan menandai puncak tersebut dengan kategori masing-masing, merah apabila abnormal dan hijau apabila normal. Sistem memecah rekaman Panjang menjadi unit *context window* secara sekuensial melalui mekanisme *rolling buffer*. Observasi pada gelombang menunjukkan model dapat mempertahankan stabilitas pembacaan sinyal yang konsisten meski adanya perubahan *baseline* dan perubahan yang muncul selama proses *streaming* berlangsung. Hal ini menjadi konfirmasi bahwa arsitektur pada saat pra-pemrosesan yang telah dibangun berhasil menjaga data sebelum masuk tahap inferensi.

Hasil dari simulasi pengujian pada data uji baru ini dapat dilihat pada tampilan antarmuka sistem pada **Gambar 4.8**.



Gambar 4.8 Hasil pengujian data uji pada antarmuka

Pada hasil pemantauan akhir dan data telah diuji seluruhnya dengan total waktu lebih dari tiga puluh menit, sistem mencatatkan Tingkat akurasi sebesar 94%. Terjadi sebuah penurunan performa dari 98% (pada *Test Set*) menjadi 94% dan pada studi kasus ini, hal ini merupakan sebuah fenome yang dikenal sebagai *Generalization Gap*. Secara analisis, hal ini mengindikasikan adanya *Distribution Shift*, dimana karakteristik fisiologis dari pasien pada rekaman uji ini memiliki variasi morfologi sinyal yang uni dan berbeda dibandingkan distribusi statistic dari data latih. Meskipun demikian, pencapaian akurasi 94% ini dalam skenario *zero-shot* dimana model tidak pernah dilatih ulang untuk mengenali pasien ini membuktikan bahwa sistem memiliki Tingkat

ketahanan atau *robustness* yang tinggi. Mengingat ambang batas toleransi minimum untuk alat bantu *preliminary screenin* umumnya berada di kisaran 90%, hasil validasi ini membuktikan bahwa sistem aman dan layak untuk diimplementasikan sebagai sebuah instrument pendukung keputusan klinis yang andal dan teruji.